

Clase 2: Probabilidad e Inferencia

Nivelación Estadística

Prof. Gabriel Duarte Zúñiga

Universidad Adolfo Ibáñez | DIAPP-2026

4 de junio de 2026

¡Bienvenidas y Bienvenidos!



Repaso Clase 1: Estadísticas Descriptivas en R

Concepto	Definición	Función en R	Ejemplo de uso
Media	Promedio aritmético: suma de los valores dividida por n	<code>mean(x, na.rm = T)</code>	<code>mean(penguins\$body_mass, na.rm = T)</code>
Mediana	Valor central de los datos ordenados; más robusta ante <i>outliers</i>	<code>median(x, na.rm = T)</code>	<code>median(penguins\$body_mass, na.rm = T)</code>
Desv. Estándar	Distancia <i>típica</i> de cada observación respecto a la media	<code>sd(x, na.rm = T)</code>	<code>sd(penguins\$body_mass, na.rm = T)</code>
Percentil	Valor bajo el cual cae el $p\%$ de los datos	<code>quantile(x, probs = p)</code>	<code>quantile(penguins\$body_mass, probs = c(.25, .75))</code>
Puntaje Z	N° de desviaciones	<code>(x - mean(x)) / sd(x)</code>	<code>(200 - mean(bdims\$hgt)) / sd(bdims\$hgt)</code>

Concepto	Definición	Función en R	Ejemplo de uso
	estándar que separan una observación de la media		
Correlación	Fuerza y dirección de la asociación lineal entre dos variables cuantitativas (-1 a $+1$)	<code>cor(x, y)</code> <code>geom_point()</code>	<code>cor(penguins\$body_mass, penguins\$flipper_len)</code>



Repaso Clase 1: Estadísticas Descriptivas en R



Para obtener varias medidas de una sola vez utilizamos: `summary(.)`

```
1 summary(penguins)
```

species	island	bill_len	bill_dep
Adelie :152	Biscoe :168	Min. :32.10	Min. :13.10
Chinstrap: 68	Dream :124	1st Qu.:39.23	1st Qu.:15.60
Gentoo :124	Torgersen: 52	Median :44.45	Median :17.30
		Mean :43.92	Mean :17.15
		3rd Qu.:48.50	3rd Qu.:18.70
		Max. :59.60	Max. :21.50
		NA's :2	NA's :2

flipper_len	body_mass	sex	year
Min. :172.0	Min. :2700	female:165	Min. :2007
1st Qu.:190.0	1st Qu.:3550	male :168	1st Qu.:2007
Median :197.0	Median :4050	NA's : 11	Median :2008
Mean :200.9	Mean :4202		Mean :2008
3rd Qu.:213.0	3rd Qu.:4750		3rd Qu.:2009
Max. :231.0	Max. :6300		Max. :2009
NA's :2	NA's :2		



Repaso: ¿Dónde Quedamos?

En la **Clase 1** aprendimos a **describir** datos:

- ▶ Medidas de **tendencia central** (media, mediana) y **variabilidad** (varianza, desviación estándar).
- ▶ **Visualización** (histograma, densidad, boxplot) y **asociación** (correlación, scatterplot).

Pero la estadística descriptiva solo resume **los datos que tenemos a mano** (una muestra).

La gran pregunta que abordaremos hoy es:

Pregunta rápida

¿Cómo pasamos de lo que observamos en **una muestra** a conclusiones sobre **toda la población**?

Para ello requerimos de la **inferencia estadística**: usar la información de una muestra para sacar conclusiones sobre la población. Y para hacerlo de forma rigurosa, reconociendo que toda muestra trae consigo cierta **incertidumbre**, primero necesitamos entender en qué consiste la probabilidad.



Objetivos Clase 2

Los objetivos específicos de la clase 2 son:

- ▶ Comprender las **nociones básicas de probabilidad** y aplicarlas a ejemplos concretos.
- ▶ Conectar la probabilidad con las **variables aleatorias** y sus **distribuciones** (binomial y normal).
- ▶ Entender por qué una muestra genera **incertidumbre** y cómo el **Teorema del Límite Central** nos ayuda a manejarla.
- ▶ Construir e interpretar **intervalos de confianza**.
- ▶ Plantear una **prueba de hipótesis** sencilla, interpretar el **p-valor** y **concluir**.

¿Qué Veremos Hoy?

1. **Probabilidad** y ejemplos aplicados.
2. **Variables aleatorias** y distribuciones conocidas (binomial).
3. La **distribución normal**.
4. **Muestreo, Teorema del Límite Central** y error estándar.
5. **Intervalos de confianza, p-valor y prueba de hipótesis** (*t-test*).



Metodología

Igual que en la Clase 1, alternaremos **exposición** breve con **preguntas**  y **ejercicios guiados**  que resolveremos juntos.

Probabilidad

- ▶ El término probabilidad se refiere al estudio del azar y la incertidumbre en cualquier situación en la que diferentes sucesos pueden ocurrir.
- ▶ **Definición *frecuentista*:** La probabilidad de un resultado está definida por la **proporción de veces** que ese resultado es observado a través de un **alto número de repeticiones de procesos aleatorios**:

$$Probabilidad = \frac{\#Eventos\ Favorables}{\#Eventos\ Totales}$$

Probabilidad (Agresti 2018)

En una muestra o experimento aleatorio, la probabilidad de que una observación tenga un resultado particular es la **proporción de veces** que ese resultado ocurriría en una secuencia **muy larga** de observaciones similares.

Probabilidad

- ▶ Dado que definimos *probabilidad* como una **proporción**, la probabilidad es un número entre 0 y 1 (o 0 y 100 si se expresa en %) que mide qué tan factible es que ocurra un resultado
 - 0 = imposible
 - 1 = seguro
 - 0.5 = tan probable como no.
- ▶ La probabilidad puede entenderse como la **frecuencia relativa** de un resultado cuando repetimos un experimento **muchas veces**. Esto implica que las probabilidades se interpretan bajo un contexto de **largo plazo**. Por ejemplo, si un meteorólogo dice que la probabilidad de lluvia hoy es del 70%, esto significa que en una **larga serie de días con condiciones atmosféricas como las de hoy**, llueve el 70% de los días.

Idea clave

Si lanzamos una moneda equilibrada muchísimas veces, la **proporción** de caras se acercará a 0.5. Esa proporción de **largo plazo** es la **probabilidad** de obtener una cara.

Proceso Aleatorio

- ▶ En un *proceso aleatorio* hay más de un posible resultado y la predicción de este está sujeto a **variabilidad**:
- ▶ Ejemplos Clásicos:
 - Tirar una moneda.
 - Tirar un dado.
- ▶ Se puede pensar como un proceso donde el resultado es **probabilístico** (o estocástico) y **no determinístico**. Es decir, hay **incertidumbre** en el resultado.

Espacio Muestral


- ▶ El *espacio muestral* es el conjunto de todos los **posibles resultados** de un proceso aleatorio. Se denota con el símbolo S . Por ejemplo:
 - Dados: $S = \{1, 2, 3, 4, 5, 6\}$.
 - Moneda: $S = \{C, S\}$.

Evento

- ▶ Un *evento* es un **subconjunto** del *espacio muestral*.
- ▶ Para el caso del lanzamiento de un dado, digamos que:
 - A representa el evento de que al tirar un dado el resultado sea un **número par**:
 $A = \{2, 4, 6\}$.
 - B representa el evento de que al tirar un dado el resultado sea un **número impar**:
 $B = \{1, 3, 5\}$.
 - C representa el evento de que al tirar un dado el resultado sea un **número primo**:
 $C = \{2, 3, 5\}$.

Diagrama de Venn

Lo anterior se pueden representar visualmente mediante un *Diagrama de Venn*: Una gráfica que usa círculos superpuestos para ilustrar las relaciones lógicas entre dos o más conjuntos de elementos.





Pregunta N° 1

Lanzamos un **dado** equilibrado de 6 caras una vez.

¿Cuál es la probabilidad de obtener un número mayor que 4?

$$2/6 \approx 0,33.$$

$$4/6 \approx 0,67.$$


$$1/6 \approx 0,17.$$

$$3/6 = 0,5.$$

Revisar

Reiniciar

Complemento de un Evento



- Definimos estos eventos en **R** como vectores:

```
1 A <- c(2,4,6)
2 B <- c(1,3,5)
3 C <- c(2,3,5)
4 S <- 1:6
```


- **Definición:** El complemento de un evento son todos los resultados en el espacio muestral que **no** corresponden al evento mismo.
- **Ejemplo:** el complemento del evento C es el conjunto de resultados de tirar un dado que **no** corresponden a números primos.

- ▶ **Notación:** C' .
- ▶ $C^c : \{1, 4, 6\}$.
- ▶ En **R** podemos usar la función setdiff() para obtener el complemento de un evento, especificando primero el espacio muestral y luego el evento:

```
1 setdiff(S,C)
```

```
[1] 1 4 6
```

Unión de Eventos




- **Definición:** La unión de dos eventos A y B es el evento formado por todos los resultados que están en A , en B o en ambos; es decir, los resultados que pertenecen a al menos uno de los dos eventos.
- **Ejemplo:** La unión de los eventos A y C es el conjunto de resultados posibles de tirar un dado que son números pares, • primos, • ambos.
- **Notación:** $A \cup C$.
- $A \cup C : \{2, 3, 4, 5, 6\}$.

- En **R** podemos usar la función **union()** para obtener la unión de dos eventos:

```
1 union(A,C)
```

```
[1] 2 4 6 3 5
```

Intersección de Eventos




- **Definición:** La intersección de dos eventos A y B es el evento que consiste en todos los resultados que están **tanto en A como en B**.
- **Ejemplo:** La intersección de los eventos A y C es el conjunto de resultados posibles de tirar un dado que son números pares **Y** primos al mismo tiempo.
- **Notación:** $A \cap C$.
- $A \cap C : \{2\}$.

- En R podemos usar la función intersect() para obtener la intersección de dos eventos:

```
1 intersect(A,C)
```

```
[1] 2
```

Eventos Mutuamente Excluyentes



- **Definición:** Los eventos mutuamente excluyentes son eventos que no pueden ocurrir al mismo tiempo.
- **Ejemplo:** El evento A y el evento B son mutuamente excluyentes porque el resultado de tirar un dado no puede ser par e impar al mismo tiempo.
- **Notación:** $A \cap B = \emptyset$

- Los eventos A y C no son mutuamente excluyentes porque el número 2 es tanto par como primo.

Eventos Independientes

- ▶ Dos eventos son **independientes** cuando el resultado de uno **no afecta** la probabilidad del otro.
 - Por ejemplo: Que la primera moneda salga cara **no afecta** la probabilidad de que salga cara o sello en el segundo lanzamiento.
- ▶ Por definición, los eventos A y B son eventos independientes, si y solo si la probabilidad de que ocurran **ambos** (es decir, su intersección) corresponde a la **multiplicación** de sus probabilidades individuales:

$$P(A \cap B) = P(A) \times P(B)$$

- ▶ Ejemplo: $P(\text{dos caras seguidas}) = 0.5 \times 0.5 = 0.25$.

Nota

La **independencia** será la clave para conectar la probabilidad con las **distribuciones** que veremos a continuación.



Pregunta N° 2

Lanzamos el **mismo dado** equilibrado **dos veces seguidas**. Cada lanzamiento es **independiente** del otro.

¿Cuál es la probabilidad de obtener un número mayor que 4 en ambos lanzamientos?

$$2/6 \approx 0,33.$$

$$4/6 \approx 0,67.$$

$$1/9 \approx 0,11.$$

$$1/36 \approx 0,03.$$

Revisar


Reiniciar

Resumen Probabilidad


Conceptos Importantes (Devore 2016)

- ▶ Un **proceso aleatorio** (en libros de estadística, llamado también *experimento*) es cualquier acción o proceso cuyo resultado está sujeto a la incertidumbre.
- ▶ El **espacio muestral** de un experimento, denotado por S , es el conjunto de todos los posibles resultados de dicho experimento.
- ▶ Un **evento** es cualquier recopilación (subconjunto) de resultados contenidos en el espacio muestral S .
- ▶ Sea que ϕ denote el evento nulo (el evento sin resultados). Cuando $A \cap B = \phi$, se dice que A y B son eventos **mutuamente excluyentes** o disjuntos.
- ▶ El **complemento** de un evento A , denotado por A' , es el conjunto de todos los resultados en S que no están contenidos en A.
- ▶ La **unión** de dos eventos A y B , denotados por $A \cup B$ y léida como A o B , es el evento que consiste en todos los resultados que están en A o en B o en ambos eventos, es decir, todos los resultados en al menos uno de los eventos: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. También $A \cup B$ se puede descomponer en dos eventos excluyentes: A y $B \cap A'$; la última es la parte de B que queda afuera de A , por lo que $P(A \cup B) = P(A) + P(B \cap A')$.
- ▶ La **intersección** de dos eventos A y B , denotada por $A \cap B$ y léida como A y B , es el evento que consiste en todos los resultados que están tanto en A como en B.


Resumen Probabilidad




(a) Diagrama de Venn de los eventos A y B



(b) La región sombreada es $A \cap B$




(c) La región sombreada es $A \cup B$




(d) La región sombreada es A'



(e) Eventos mutuamente excluyentes



(f) La región sombreada es $A \cup B \cup C$



(g) La región sombreada es $A \cap B \cap C$

Fuente: (**Devore 2016**)

Aplicando el Complemento

- ▶ Consideremos el lanzamiento de **2** monedas. En este caso, el espacio muestral sería $S = \{CC, CS, SC, SS\}$ (4 resultados igualmente probables)
- ▶ Calculemos las siguientes probabilidades:
 - $P(\text{exactamente una cara } (X=1)) = \frac{2}{4} = 0.5$
 - $P(\text{al menos una cara } (X \geq 1))$: en vez de contar $\{CC, CS, SC\}$, usamos el **complemento** de ese evento (que en este caso, sería $P(X < 1)$). El único caso sin caras es $\{SS\}$:

$$P(\text{al menos una cara}) = 1 - P(\text{ninguna cara}) = 1 - \frac{1}{4} = 0.75$$

Tip

Muchas veces puede ser útil usar el **complemento** de un evento para calcular probabilidades: $P(A) = 1 - P(A')$.

Proceso Aleatorio con Repeticiones

- Asumamos que repetimos el proceso aleatorio de tirar una moneda y que registramos como evento X el número de veces que sale *cara* en n lanzamientos de moneda. Entonces:

$$P(Cara) = \lim_{n \rightarrow \infty} \frac{X}{n}$$

$$P(Cara) = \frac{1}{2}$$

Lanzar 1 Vez una Moneda

- ▶ Definamos un vector *moneda* con los posibles eventos y simulemos un solo lanzamiento de esa moneda.
- ▶ Para hacerlo en R, debemos utilizar la función `sample()` considerando los siguientes argumentos:
 - **x**: Un vector de uno o más elementos entre los cuales elegir, o un número entero positivo.
 - **size**: Un número entero no negativo que indica el número de elementos a elegir.
 - **replace**: Un valor lógico que indica si es que el muestreo debe ser con reposición (**= T**) o no (**= F**).
- ▶ Además, *seteamos una semilla* con la función `set.seed()` para definir un proceso pseudo-aleatorio que nos permita replicar los mismos resultados. En la medida que se utilice la misma semilla, todos los procesos aleatorios que se hagan en adelante serán replicables siempre y cuando utilicen la misma semilla (en la práctica, cualquier número natural).

```
1 set.seed(123)
2 moneda <- c("cara", "sello")
3 sample(moneda, size = 1)
```

```
[1] "cara"
```

Repitamos 20 Veces Este Proceso

```
1 set.seed(123)
2 tirar_moneda <- sample(moneda, size = 20, replace = TRUE)
3 table(tirar_moneda)
```

```
tirar_moneda
cara sello
  11     9
```

- Dados estos resultados, vemos que $P(Cara) = \frac{11}{20} = 55\%$


Repitamos 5.000 Veces Este Proceso

```
1 set.seed(123)
2 tirar_moneda <- sample(moneda, size = 5000, replace = TRUE)
3 table(tirar_moneda)
```

```
tirar_moneda
cara sello
2499  2501
```

- En este caso vemos que $P(Cara) = \frac{2499}{5000} = 49,98\%$

Frecuencia Relativa Acumulada de 10.000 repeticiones



La proporción de caras se acerca a **0.5** a medida que n crece, tal como vimos previamente. A más repeticiones, **más cerca** del valor verdadero. Recordar que la probabilidad implicaba pensar en un resultado de **largo plazo**, es decir, con varias repeticiones.



Simular lanzamientos

Anteriormente ya calculamos que la probabilidad de obtener un número **mayor que 4** en el lanzamiento de un dado es $2/6 \approx 0,33$. Confirmémoslo **simulando 1000 lanzamientos** de un dado y observando la frecuencia relativa de cada resultado (*también puede usar la función `prop.table()` para sacar proporciones*):

Exercise [Start Over](#)

[Run Code](#)

```
1 set.seed(123)
2 dado <- 1:6
3 tiros <- sample(_____, size = _____, replace = TRUE)
4
5 table(_____)                # conteo por cara
6 sum(tiros > _____)      # (= conteo de 5 y 6)
7 sum(_____) / length(tiros)  # proporción de eventos favorables
```

Exercise [Start Over](#)

[Run Code](#)

```
1 set.seed(123)
2 dado <- 1:6
3 tiros <- sample(_____, size = _____, replace = TRUE)
4
5 # Proporción de cada resultado (frecuencia relativa)
6 prop.table(table(_____))
```


Variables Aleatorias

- ▶ El concepto de variable aleatoria nos permite pasar de los resultados experimentales a una **función** numérica de los resultados.
- ▶ Existen fundamentalmente dos tipos diferentes de variables aleatorias:
 - **Variables aleatorias discretas**
 - **Variables aleatorias continuas**
- ▶ Así, una función que asigna un resultado numérico a un proceso aleatorio se conoce como **variable aleatoria**.

Variables Aleatorias Discretas

- ▶ Para una **variable aleatoria discreta**, estos resultados numéricos toman valores aislados (entre dos números no existe ninguno intermedio) y los posibles valores son **finitos**.
- ▶ Usaremos letras mayúsculas, como X , Y , y Z , para representar variables aleatorias y minúsculas (x , y , y z) para indicar los resultados observados.
- ▶ Definamos el siguiente proceso aleatorio: Tirar **3 veces** una misma moneda y $X = \text{N}^\circ$ de caras
- ▶ En este ejemplo, el espacio muestral tiene 8 resultados, y X puede tomar los valores 0, 1, 2, 3:

$$\underbrace{\{SSS\}}_0, \underbrace{\{CSS, SCS, SSC\}}_1, \underbrace{\{CCS, CSC, SCC\}}_2, \underbrace{\{CCC\}}_3$$

- ▶ Así pasamos de “caras y sellos” a **números** sobre los que podemos calcular probabilidades.

Distribución de Probabilidad

La **distribución** de una variable aleatoria nos dice qué probabilidad tiene **cada valor posible**. Para $X = \text{N}^\circ$ de caras en 3 lanzamientos:

x	0	1	2	3
$P(X = x)$	1/8	3/8	3/8	1/8

- ▶ Todas las probabilidades son ≥ 0 .
- ▶ La suma de todas las probabilidades es **1**.

① Función Masa de Probabilidad (pmf)

La función que asigna una probabilidad a cada valor de una variable **discreta** se llama **función de masa de probabilidad** (*pmf*).

PMF y CDF

- ▶ **PMF:** La distribución de probabilidad o función de masa de probabilidad de una variable discreta se define para cada número x como $p(x) = P(X = x)$
 - Es decir, para cada valor posible x de la variable aleatoria, la función de masa de probabilidad especifica la probabilidad de **observar dicho valor** cuando se realiza el proceso aleatorio
- ▶ **CDF:** La función de distribución acumulada $F(x)$ de una variable aleatoria discreta X con función de masa de probabilidad $p(x)$ se define para cada número x como:
$$F(x) = P(X \leq x) = \sum_{y: y \leq x} p(y)$$
 - Es decir, que para cualquier número x , $F(x)$ es la probabilidad de que el valor observado de X sea **menor o igual** a x .

Aplicando la pmf

- Digamos que X es una variable aleatoria discreta que representa el número total de *caras* en 3 tiros de moneda. ¿Cuál es $P(X = 2)$?

$$P(X = 2) = \frac{3}{8} = 0.375$$

x	0	1	2	3
$P(X = x) = f(x)$	$f(0)=0,125$	$f(1)=0,375$	$f(2)=0,375$	$f(3)=0,125$

Probemos haciendo el experimento 10.000 veces:

```
1 resultados <- replicate(expr = sum(sample(moneda, 3, replace = TRUE) == "cara"), n = 10000)
2 table(resultados)/10000
```

resultados

0	1	2	3
0.1283	0.3674	0.3758	0.1285

Función de Distribución Acumulada (cdf) y pmf

	x	0	1	2	3
pmf	$P(X = x) = f(x)$	$f(0)=0,125$	$f(1)=0,375$	$f(2)=0,375$	$f(3)=0,125$
cdf	$P(X \leq x) = F(x)$	$F(0)=0,125$	$F(1)=0,5$	$F(2)=0,875$	$F(3)=1$

PMF y CDF en R

- ▶ El paquete `stats` permite calcular fácilmente las funciones de probabilidad (*pmf*) y las funciones de probabilidad acumulada (*cdf*). La sintaxis general es: `prefijo + distr` donde `distr` es el sufijo de la abreviación de la distribución de probabilidad (por ejemplo, `binom` para la binomial, `norm` para la normal, y así sucesivamente); mientras que el *prefijo* puede ser uno de los siguientes valores:
 - *d* para la **pmf/pdf**. En R se le llama *density*
 - *p* para la **cdf**. En R se le llama *distribution function*
 - *q* para los **cuantiles**. En R se le llama *quantile function*
 - *r* para generar **números aleatorios** según la distribución indicada. En R se le llama *random variates* o *random generation*

La Familia de Funciones de Distribución en R

R tiene una familia de funciones para cada distribución. Para la binomial, el sufijo es **binom**:

Prefijo	Pregunta que responde	Función Ejemplo
d	¿Probabilidad de un valor exacto ? En el caso discreto $P(X = x)$ y altura de la curva si es continua	<u>dbinom()</u>
p	¿Probabilidad acumulada ? $P(X \leq x)$	<u>pbinom()</u>
q	¿Qué valor deja una probabilidad acumulada dada?	<u>qbinom()</u>
r	Generar valores aleatorios	<u>rbinom()</u>

Tip

Recuerden que el mismo patrón aplica a la distribución normal que veremos más adelante (**dnorm**, **pnorm**, ...) y a otras distribuciones. ¡Solo cambia el sufijo!

Distribución Binomial

Un proceso aleatorio sigue una distribución binomial si se cumplen las siguientes 4 condiciones (**Devore 2016**):

1. El experimento consta de una secuencia de n experimentos más pequeños llamados ensayos, donde n se fija antes del experimento.
 2. Cada ensayo puede dar por resultado uno de los mismos **dos resultados** posibles (ensayos dicotómicos) los cuales se denotan como éxito (S) y como falla (F).
 3. Los ensayos son **independientes** entre sí, de modo que el resultado en un ensayo particular **no** influye en el resultado de cualquier otro ensayo.
 4. La probabilidad de éxito $P(S)$ es **constante** de un ensayo a otro. Esta probabilidad se denota por p .
- ▶ Tal y como se mencionó anteriormente, el **lanzamiento de una moneda** cumple precisamente con estas características, por lo que sigue una **distribución binomial**.
 - ▶ Por ejemplo, el proceso aleatorio de lanzar 3 monedas y contar la cantidad de caras obtenidas cumple estas 4 condiciones:
 - $n = 3$
 - $p = 0.5$
 - éxito = “cara”.

Aplicación en R: `dbinom()`

- ▶ Siguiendo con el ejemplo de la moneda, para calcular la probabilidad de obtener **2 caras** en **3 lanzamientos** de moneda, podemos utilizar la función `dbinom()` de la siguiente manera, sabiendo que $x = 2$, $n = 3$ y $p = 0.5$:

```
1 dbinom(2, size = 3, prob = 0.5)
```

```
[1] 0.375
```

- ▶ El resultado es **0.375 = 3/8**, exactamente lo que habíamos contado en la tabla. Este cálculo directo nos ahorra tener que enumerar el espacio muestral del proceso aleatorio: $\{CCC, CCS, CSC, SCC, CSS, SCS, SSC, SSS\}$.

Aplicación en R: `pbinom()`

- ▶ Si ahora quisiéramos calcular cuál es la probabilidad de tener **1 cara o menos** en los mismos 3 lanzamientos, podemos utilizar la función `pbinom()` de la siguiente manera:

```
1 pbinom(1, size = 3, prob = 0.5)
```

```
[1] 0.5
```

$\{CCC, CCS, CSC, SCC, CSS, SCS, SSC, SSS\}$.

- ▶ ¿Y si quisiéramos obtener la probabilidad de obtener **al menos 1** cara?
- ▶ Para responder a ello, podemos usar el **complemento**: $P(X \geq 1) = 1 - P(X = 0)$.
- ▶ `pbinom(0, 3, 0.5)` entrega $P(X \leq 0)$, que aquí es igual a $P(X = 0)$:

```
1 1 - pbinom(0, size = 3, prob = 0.5)
```

```
[1] 0.875
```

- ▶ El resultado es **0.875 = 7/8**: la misma lógica del complemento que usamos con las dos monedas, pero ahora calculado mediante funciones de R.

Aplicación en R: `qbinom()`

- ▶ La función `qbinom()` en R permite encontrar el valor de una variable binomial asociado a una probabilidad acumulada determinada. Es decir, calcula el cuantil (o percentil) de la distribución binomial. Los argumentos básicos de la función son:
 - `p`: La probabilidad acumulada.
 - `size`: El número de ensayos (lanzamientos de la moneda).
 - `prob`: La probabilidad de éxito en cada ensayo (probabilidad de obtener cara en cada lanzamiento).
- ▶ `qbinom(p, size, prob)` devuelve el menor valor de k tal que la probabilidad acumulada $P(X \leq k)$ sea al menos p , donde X es una variable aleatoria binomial con parámetros `size` y `prob`
- ▶ Por los ejercicios anteriores, sabemos que $P(X \leq 0) = 0.125$, $P(X \leq 1) = 0.5$, $P(X \leq 2) = 0.875$ y $P(X \leq 3) = 1$
- ▶ Por lo tanto, si queremos saber hasta qué punto concreto de los valores que podría tomar X se acumula el 87.5% de la probabilidad, debemos ejecutar lo siguiente:

```
1 qbinom(0.875, 3, 0.5)
```

```
[1] 2
```



Aplicación: Distribución Binomial

Una prueba tiene **5 preguntas** de verdadero/falso. Un estudiante **responde al azar** ($p = 0.5$ de acertar cada una). Complete el código para calcular la probabilidad de acertar **exactamente 3**:

Exercise

 Start Over

 Show Hint

 Run Code

```
1 _____(_____, size = _____, prob = _____)
```

De lo Discreto a lo Continuo

- ▶ La distribución binomial es **discreta**: X toma valores separados (0, 1, 2, 3...).
- ▶ Pero muchas variables son **continuas**, es decir, pueden tomar **cualquier** valor en un rango (altura, ingreso, temperatura).
- ▶ En variables continuas ya no preguntamos por $P(X = x)$ exacto (es prácticamente 0), sino por la probabilidad de caer en un **intervalo**, que corresponde al **área bajo la curva** de su función de densidad, es decir, principalmente nos interesamos en calcular probabilidad mediante **p** funciones (ejemplo: `pnorm()`).

La distribución continua más importante (y protagonista para introducir reglas y conceptos de inferencia estadística) es la **distribución normal**.

La Distribución Normal

- ▶ Es una distribución **continua** con forma de **campana** simétrica.
- ▶ Se describe con **dos parámetros**:
 - μ (media): dónde está el **centro**.
 - σ (desviación estándar): qué tan **ancha** es.
- ▶ Se abrevia $X \sim \mathcal{N}(\mu, \sigma^2)$.
- ▶ En ella se cumple que **media = mediana = moda**.

El Efecto de los Parámetros

μ **mueve** la curva hacia la izquierda o derecha, mientras que σ la hace más **ancha o angosta**:

.

Ejemplo: La Altura de una Población

Supongamos que la **altura** (en cm) de una población se distribuye de forma normal con media **177** y desviación estándar **10**:

$$X \sim \mathcal{N}(177, 10^2)$$

Queremos calcular probabilidades sobre la altura usando `pnorm()`.

Calcular Probabilidades con `pnorm()`

- ¿Cuál es la probabilidad de que alguien mida menos de 160 cm con la distribución anterior?

Sabemos que `pnorm()` entrega el **área a la izquierda** (la cdf, $P(X \leq x)$):

```
1 pnorm(160, mean = 177, sd = 10)
```

```
[1] 0.04456546
```

Por lo tanto, hay un **4.5%** de probabilidad de medir menos de 160 cm.

Calcular Probabilidades con `pnorm()`

- ¿Cuál es la probabilidad de medir más de 180 cm?

Ahora necesitamos saber el área a la derecha, es decir, el complemento:

```
1 1 - pnorm(180, mean = 177, sd = 10)
```

```
[1] 0.3820886
```

O bien usando el argumento `lower.tail = FALSE`:

```
1 pnorm(180, mean = 177, sd = 10, lower.tail = FALSE)
```

```
[1] 0.3820886
```

Lo que nos indica que un **38.2%** mide más de 180 cm.



Ejercicio Guiado: Normal

Con la misma distribución de altura $\mathcal{N}(177, 10^2)$, complete el código para calcular la probabilidad de medir **entre 160 y 180 cm**.

Pista: es el área a la izquierda de 180 menos el área a la izquierda de 160.

Exercise [↺ Start Over](#)

[▶ Run Code](#)

```
1 pnorm(_____, 177, 10) - pnorm(_____, 177, 10)
```

El resultado es **0.573**: poco más de la mitad de la población mide entre 160 y 180 cm.

Puntaje Z y la Regla Empírica

- Recordemos de la Clase 1 el **puntaje Z**, el cual mide a cuántas desviaciones estándar está un valor de la media:

$$z = \frac{x - \mu}{\sigma}$$

- En **cualquier** distribución con forma de campana se cumple la **Regla Empírica**:

Rango	% de los datos
$\mu \pm 1\sigma$	$\approx 68\%$
$\mu \pm 2\sigma$	$\approx 95\%$
$\mu \pm 3\sigma$	$\approx 99.7\%$

Estos porcentajes son el área bajo la curva normal, y serán la base para construir los **intervalos de confianza** que veremos más adelante.



Pregunta N° 3

La altura sigue una $\mathcal{N}(177, 10^2)$. Una persona mide **197 cm**.

¿Qué podemos decir de su puntaje Z?

$z = 2$: está a 2 desviaciones sobre la media, entre el 2,5% más alto.

$z = 2$: es un valor imposible bajo esta distribución.

$z = 20$: está muy lejos de la media.

$z = 0,5$: es un valor muy común.

Revisar

Reiniciar

Recordar: Población vs. Muestra

- ▶ **Población** (N): el grupo **completo** que nos interesa (por ejemplo, todos los hogares de Chile).
- ▶ **Muestra** (n): un **subconjunto** de la población que efectivamente observamos.
- ▶ Un **parámetro** describe a la población (la media real μ). Casi nunca lo conocemos.
- ▶ Un **estadístico** se calcula desde la muestra (la media muestral $\bar{x}$). Es nuestra **estimación** del parámetro.



Tip

Hacemos **inferencia**: usamos el estadístico de una muestra para sacar conclusiones sobre el parámetro de la población.

El Problema: la Incertidumbre

- ▶ Si tomamos **otra** muestra, obtendremos una media **distinta**. Y otra más, otra distinta.
- ▶ Cada muestra entrega una estimación algo diferente: existe **variabilidad muestral**.

Pregunta rápida

¿Cómo se comportan todas esas **medias muestrales** si repitiéramos el muestreo muchísimas veces?

La respuesta es uno de los resultados más importantes de la estadística: el **Teorema del Límite Central**.

Teorema del Límite Central (TLC)

El **TLC** dice que, si tomamos muchas muestras de tamaño n y calculamos la media de cada una:

- ▶ La distribución de **esas medias** tiende a una **distribución normal**...
- ▶ ...aunque la población original **no sea normal**,
- ▶ La media de estas medias muestrales está centrada justo en la **media poblacional** μ ,
- ▶ y su distribución es **más angosta** mientras **mayor** sea n .

Veamos una breve animación que lo explica:

Bunnies, Dragons and the 'Normal' World: Central I

The New York Times



Ver en

La Edad de Independencia según el Censo 2024

Usemos la **edad** de la comuna de Independencia a partir de la base de datos de personas del Censo 2024. Como tenemos a **todas** las personas censadas, conocemos los parámetros poblacionales μ y σ :

```
1 library(readxl)
2 censo <- read_excel("data/censo24-personas-independencia.xlsx") # columna: edad
3 censo |> summarise(mu = mean(edad), sigma = sd(edad)) |> kable()
```

mu	sigma
35.91319	20.75632

- ▶ La distribución de la edad **no es normal**.
- ▶ En la mayoría de los casos **no** conocemos μ : solo tenemos **muestras** y realizamos estimaciones con $\hat{\mu} = \bar{x}$.
- ▶ Cada muestra da un $\hat{\mu}$ **distinto**. ¿Cómo se distribuyen?

1.000 Muestras de la Edad: TLC

Tomamos **1.000 muestras** y calculamos la **media de la edad** en cada una, para tres tamaños muestrales ($n = 10, 100, 500$):

Aunque la población **no** es normal, la distribución de las **medias** se aproxima a una normal, **centrada en la media poblacional** (línea roja) y **cada vez más angosta** a mayor n . Eso es el **Teorema del Límite Central**.

Resumen

En general, si sacamos una **muestra aleatoria** de tamaño n desde una población N , entonces:

- ▶ La media muestral $\bar{X}$ es un estimador insesgado de μ , y su dispersión, medida por el error estándar $\sigma/\sqrt{n}$ disminuye al aumentar n . Además, por el TCL, para n suficientemente grande la distribución de $\bar{X}$ a una Normal, sin importar la distribución original de la población.
- ▶ Los resultados basados en la muestra podrían ser **generalizados a la población**.
- ▶ La estimación puntual, $\hat{\mu}$, es una “**buena suposición**” del parámetro poblacional desconocido, μ .
- ▶ Entonces, en vez de hacer un censo (costoso en muchos sentidos), podemos hacer **inferencia sobre una población usando muestreo**.

Error Estándar (SE)

- ▶ El error estándar es una métrica única que resume la variabilidad en la distribución muestral de un estadístico.
- ▶ El error estándar se puede estimar utilizando una estadística basada en la **desviación estándar** s de los valores de la muestra y el **tamaño de la muestra** n :

$$SE = \frac{s}{\sqrt{n}}$$

- ▶ A medida que aumenta el tamaño de la muestra, el error estándar disminuye: $\uparrow n \Rightarrow \downarrow SE$, tal y como vimos con los ejemplos anteriores (distribuciones más estrechas en torno al promedio poblacional).

La intuición central de la inferencia

Mientras **más grande** es la muestra (n), **más pequeño** es el error estándar, lo que hace que nuestra estimación sea **más precisa**.



Pregunta N° 4

Dos equipos estiman el ingreso promedio de una comuna. El equipo A usa una muestra de **100** personas; el equipo B, de **1.000**.

¿Qué estimación tendrá, en general, un menor error estándar?

La del equipo B, porque a mayor n menor es el error estándar.

La del equipo A, porque usa menos datos.

Ambas tendrán el mismo error estándar.

No se puede saber sin conocer la media.

Revisar

Reiniciar

Intervalo de Confianza (IC)

- ▶ Una estimación puntual (como $\bar{x}$) casi nunca es **exactamente** igual al parámetro. Por eso reportamos un **rango** de valores plausibles.
- ▶ Un **intervalo de confianza** es ese rango, construido para contener al parámetro con un nivel de confianza dado (típicamente **95%**):

$$\bar{x} \pm c \times SE$$

donde c es un valor crítico (cercano a **2** para el 95%, por la Regla Empírica).

⚠ Interpretación correcta

Si repitiéramos el muestreo muchas veces, cerca del **95%** de los intervalos construidos **contendría** el verdadero parámetro. **No** es que “hay 95% de probabilidad de que el parámetro esté en este intervalo particular”.

Construyendo Manualmente un IC en R

Usaremos `bdims` (openintro), con 507 medidas físicas. Estimemos la **altura promedio** (`hgt`) con un IC al 95%:

Exercise [Start Over](#)

[Run Code](#)

```
1 x_bar <- _____()           # media muestral
2 s     <- _____()           # desviación estándar
3 n     <- length()                # tamaño muestral
4 se    <- _____ / sqrt(_____) # error estándar
5
6 # Valor crítico t para 95% e intervalo
7 c_t   <- qt(0.975, df = n - 1)
8 _____ + _____ * c(-_____, _____)
```

El resultado es un **rango** alrededor de la media: nuestra estimación de la altura promedio **con su incertidumbre**.

La Lógica de una Prueba de Hipótesis

Una **prueba de hipótesis** nos ayuda a decidir si los datos respaldan una afirmación. Siempre planteamos **dos** hipótesis:

- ▶ **Hipótesis nula** (H_0): “no hay efecto / no hay diferencia”. Es lo que asumimos por defecto.
- ▶ **Hipótesis alternativa** (H_1): “sí hay efecto / sí hay diferencia”. Es lo que queremos probar.

La idea

Asumimos que H_0 es cierta y nos preguntamos: *¿qué tan sorprendentes serían estos datos si H_0 fuera verdad?* Si son **muy** sorprendentes, dudamos de H_0 .

El p-valor

- ▶ El **p-valor** mide esa “sorpresa”: es la probabilidad de observar un resultado **al menos tan extremo** como el nuestro **si** H_0 fuera cierta.
- ▶ Lo comparamos con un umbral α (habitualmente **0.05**):
- ▶ **p-valor** < 0.05 $\rightarrow$ resultado poco probable bajo $H_0 \rightarrow$ **rechazamos** H_0 (hay evidencia de un efecto).
- ▶ **p-valor** ≥ 0.05 $\rightarrow$ resultado compatible con $H_0 \rightarrow$ **no rechazamos** H_0 (no hay evidencia suficiente).

⚠ Importante

“No rechazar H_0 ” **no** prueba que H_0 sea verdad; solo significa que no tenemos evidencia suficiente en su contra.

La Prueba t (t -test)

- ▶ La **prueba t** es una de las más usadas. Sirve, por ejemplo, para comparar la **media de dos grupos**.
- ▶ Pregunta clave: *¿la diferencia de medias que observo es real, o pudo deberse al azar del muestreo?*
- ▶ Ejemplo con `bdims`: ¿difiere la **altura promedio** entre hombres y mujeres?
 - H_0 : la altura promedio es **igual** en ambos grupos.
 - H_1 : la altura promedio es **distinta**.

En `R` esto se resuelve con **una sola función**: `t.test()`:

- ▶ **Fórmula y datos**: `variable ~ grupo` especifica *qué se compara y por qué factor*. El argumento `data` indica el data frame. `t.test(hgt ~ sex, data = bdims)` se lee: “compara `hgt` según `sex`”.
- ▶ **Hipótesis alternativa** (`alternative`): por defecto es `"two.sided"` ($H_1 : \mu_1 \neq \mu_2$); puede ser `"less"` o `"greater"` si la pregunta es direccional.
- ▶ **Varianzas iguales** (`var.equal`): por defecto es `FALSE`, lo que aplica la versión de **Welch**, que es más robusta y no asume que ambos grupos tienen la misma dispersión. Con `var.equal = TRUE` se obtiene la prueba t clásica de Student.

Aplicación: `t.test()` en R

```
1 t.test(hgt ~ sex, data = bdim)
```

Welch Two Sample t-test

```
data: hgt by sex
t = -21.059, df = 494.73, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -14.07406 -11.67201
sample estimates:
mean in group 0 mean in group 1
    164.8723      177.7453
```

Al ejecutarlo, nos fijamos en **dos resultados**:

- ▶ El **p-valor**: si es **< 0.05**, hay evidencia de una diferencia real.
- ▶ El **intervalo de confianza** de la diferencia: si **no contiene el 0**, refuerza que la diferencia es significativa.

Para la altura por sexo, el p-valor es **muy pequeño** (≈ 0): rechazamos H_0 y concluimos que **sí** existe una diferencia de altura entre hombres y mujeres en estos datos.



Test de Hipótesis

Queremos saber si el **peso promedio** (**wgt**) difiere entre hombres y mujeres usando el dataset **bdims**. Complete y ejecute la prueba:

Exercise

[Start Over](#)

[Run Code](#)

```
1 # H0: el peso promedio es igual entre sexos
2 # H1: el peso promedio es distinto entre sexos
3 t.test(_____ ~ _____, data = bdims)
```

💡 Para concluir, responde

1. ¿El **p-valor** es menor que 0.05?
2. Según eso, ¿**rechaza** o **no rechaza** H_0 ?
3. Redacte la conclusión en palabras simples.



Pregunta N° 5

Una prueba t comparando dos grupos arroja un **p-valor de 0.32**.

¿Qué concluimos (con $\alpha = 0.05$)?

No rechazamos H_0 : no hay evidencia suficiente de una diferencia.

Rechazamos H_0 : hay una diferencia significativa.

Probamos que los dos grupos son idénticos.

El resultado es muy extremo.

Revisar

Reiniciar

Resumen: Lo Esencial de la Clase

Tip

- ▶ La **probabilidad** mide la factibilidad de un resultado y se conecta con las **variables aleatorias** y sus **distribuciones** (binomial, normal).
- ▶ La **distribución normal** describe muchos fenómenos en la práctica y permite estimar de manera precisa la variación de los estadísticos usados en muestras.
- ▶ Sabemos que debido a la **variabilidad muestral** existe incertidumbre. No obstante, el **TLC** nos dice que las medias muestrales se distribuyen de forma **normal**, con menor **error estándar** a mayor n . Esto permite mostrar empíricamente la relevancia del tamaño de una muestra para hacer inferencia estadística.
- ▶ Un intervalo de confianza (IC) para un parámetro es un intervalo de números dentro del cual se cree que se encuentra dicho parámetro. La probabilidad de que este método produzca un intervalo que contenga el parámetro se denomina nivel de confianza. Este nivel de confianza se elige como un número cercano a 1, como 0,95 o 0,99.
- ▶ **Interpretación Correcta del IC:** (Çetinkaya-Rundel y Hardin 2024) Tenemos un XX% de confianza en que el parámetro poblacional se encuentra entre el límite inferior y el límite superior (donde ambos son valores numéricos). Un lenguaje **incorrecto** podría describir el intervalo de confianza como una representación del parámetro poblacional con una probabilidad determinada. Este es uno de los errores más comunes: El nivel de

confianza solo cuantifica la plausibilidad de que el parámetro se encuentre dentro del intervalo.

- La **prueba de hipótesis** y el **p-valor** nos permiten decidir, con un criterio claro, si los datos respaldan una afirmación.

Lo que Viene: Módulo 2

Estos fundamentos son la base de lo que viene en el **Módulo 2**:

- ▶ **Herramientas de Ciencia de Datos con R**: importar, ordenar, transformar, visualizar y comunicar datos.
- ▶ **Estadística Aplicada con R**: inferencia estadística, **regresión lineal** y casos aplicados a políticas públicas.

Para reforzar

Recuerden que cada clase cuenta con una **guía de ejercicios** en Webcursos para practicar de forma autónoma. ¡La práctica es la mejor forma de aprender!

¡Gracias por su Atención!

Espacio final para **preguntas**.

- ▶  La presentación y grabación se subirán a **Webcursos**.
- ▶  Consultas a través del **foro del curso**.

Bibliografía

Agresti, Alan. 2018. *Statistical methods for the social sciences*. Fifth edition, global edition. Harlow: Pearson Education, Limited.

Metinkaya-Rundel, Mine, y Johanna Hardin. 2024. *Introduction to modern statistics*. 2e ed. Vereinigte Staaten: OpenIntro, Inc.
<https://openintro-ims.netlify.app/>.

Devore, Jay L. 2016. *Probabilidad y estadística para ingeniería y ciencias (9a. ed.)*. Distrito Federal: CENGAGE Learning.





Speaker notes