

Clase 5: Inferencia Estadística

Análisis de Datos y Estadística Computacional

Prof. Gabriel Duarte Zúñiga

Universidad Adolfo Ibáñez | DIAPP-2026

23 de junio de 2026

¡Bienvenid@s a la Clase 5!

Inicio de la Unidad II

Comenzamos la **Unidad II: Estadística Aplicada con R**. Hasta ahora describimos y visualizamos datos; ahora aprenderemos a **sacar conclusiones** sobre una población a partir de una muestra.

Los objetivos de esta clase son:

- ▶ Distinguir entre **describir** e **inferir**.
- ▶ Entender el concepto de **parámetro** y **estimador**.
- ▶ Construir **intervalos de confianza** con *bootstrap*.
- ▶ Realizar **pruebas de hipótesis** y entender el **p-value**.
- ▶ Reconocer los **errores tipo I y tipo II**.

Usaremos el paquete **infer** ([Ismay, Kim, y Valdivia 2025](#)), que implementa la inferencia de forma ordenada (*tidy*). También usaremos el paquete de la referencia guía de la segunda unidad de este curso: **moderndive**

Describir vs Inferir

Describir

- ▶ Resume la información de los datos que **tenemos**.
- ▶ No conlleva incertidumbre: no hacemos una predicción sobre un resultado numérico.
- ▶ Ej: “el promedio de edad de **esta muestra** es 38 años”.

Inferir


- ▶ Saca conclusiones sobre una **población** a partir de una **muestra**.
- ▶ Sí conlleva incertidumbre: sí hacemos predicciones numéricas.
- ▶ Ej: “el promedio de edad de **Chile** está entre 37 y 39 años”.

Las dos herramientas centrales de la inferencia son los **intervalos de confianza** y las **pruebas de hipótesis** ([Çetinkaya-Rundel y Hardin 2024](#)).

Población, muestra y parámetros

Población vs Muestra

- ▶ **Población** (N): el grupo completo que queremos estudiar (ej. todos los habitantes de Chile).
- ▶ **Muestra** (n): un subconjunto de la población obtenido mediante algún procedimiento de muestreo (ej. muestreo aleatorio).



Parámetro vs Estimador

	Población	Muestra
Nombre	Parámetro	Estimador (estadístico)
¿Se conoce?	Casi nunca (es lo que buscamos)	Sí, lo calculamos a partir de los datos
Media	μ	$\bar{x}$
Proporción	p	$\hat{p}$
Desv. estándar	σ	s



Tip

El objetivo de la inferencia es **estimar un parámetro desconocido** (como p) usando un **estadístico** que sí podemos calcular (como $\hat{p}$).

Nuestro ejemplo de hoy

Queremos estimar el **porcentaje de personas en Chile que se identifican con un pueblo originario**.

- ▶ El verdadero valor de esa proporción (**parámetro** p) es desconocido.
- ▶ Para fines de esta clase, trabajaremos con una **población simulada** en la que sí conocemos el valor real: $p = 0.30$ (29%).
- ▶ Esto nos permitirá **evaluar** si los métodos de inferencia que usaremos funcionan (son capaces de recuperar ese valor).

Nuestro ejemplo de hoy

```
1 set.seed(2026)
2 # Población simulada: proporción real de pertenencia a pueblos originarios
3 # (valor poblacional conocido para fines pedagógicos)
4 poblacion <- tibble(
5   p_originario = sample(c("si", "no"), size = 100745,
6                         replace = TRUE, prob = c(0.3, 0.7))
7 )
8
9 # El parámetro poblacional (que en la vida real NO conoceríamos)
10 poblacion |>
11   count(p_originario) |>
12   mutate(prop = n / sum(n))
```

```
# A tibble: 2 × 3
  p_originario      n  prop
  <chr>         <int> <dbl>
1 no           70292 0.698
2 si           30453 0.302
```

Tomamos una muestra

En la práctica solo tenemos **una muestra** de esta población. Por ejemplo, consideremos una muestra de 300 personas:

```
1 # Una única muestra de 300 personas
2 muestra <- poblacion |> slice_sample(n = 300)
3
4 muestra |>
5   count(p_originario) |>
6   mutate(prop = n / sum(n))
```

```
# A tibble: 2 × 3
  p_originario      n prop
  <chr>         <int> <dbl>
1 no             214 0.713
2 si              86 0.287
```

Advertencia

El estimador $\hat{p}$ de nuestra muestra **no es exactamente** 0.30. Y si hiciéramos nuevos “muestreos”, cada muestra nos entregaría un valor distinto de $\hat{p}$. A esa variabilidad la llamamos **error muestral**, y es precisamente lo que la inferencia busca cuantificar.

La pregunta clave

Nota

Si solo tenemos **una** muestra y su estimador $\hat{p}$...


¿cómo sabemos **qué tan lejos** puede estar del verdadero parámetro p ?

La respuesta está en entender cómo **variaria** nuestro estimador si pudiéramos tomar muchas muestras. Para eso usaremos el **bootstrap**.

Intervalos de confianza

La idea del Bootstrap

- **Problema:** solo tenemos una muestra, y no podemos volver a extraer más muestras de la población para estudiar la variabilidad de nuestras estimaciones.
- **Solución (*bootstrap*):** tratamos nuestra primera muestra como si fuera la población y extraemos nuevas muestras (“remuestreo”) con reemplazo, del mismo tamaño.



¿Por qué con reemplazo?

- ▶ Si remuestreáramos **sin** reemplazo, siempre obtendríamos exactamente la misma muestra (los mismos 300 casos) por lo que todas las muestras serían idénticas.
- ▶ Con **reemplazo**, una misma persona puede ser seleccionada más de una vez, mientras que otras pueden no aparecer, generando muestras (“remuestras”) **similares, pero no iguales**.
- ▶ Como cada remuestra es distinta, cada una produce un $\hat{p}$ distinto → Al repetir este proceso muchas veces, podemos simular la **variabilidad** de nuestro estimador.



Tip

La distribución de los $\hat{p}$ de las remuestras se llama **distribución bootstrap**, y aproxima cómo variaría nuestro estimador entre muestras.

El paquete **infer**: la idea central

Independientemente del test que usemos, siempre nos estamos haciendo la **misma pregunta**:

Nota

¿El efecto que observo en mis datos es **real**, o se explica simplemente por el **azar** del muestreo?

Para responderla, partimos asumiendo que “**el efecto observado se debió simplemente al azar.**” (la hipótesis nula H_0), y simulamos cómo se verían los datos en ese mundo. Si nuestro resultado observado es muy raro en ese mundo simulado, entonces rechazamos H_0 .

infer organiza esta lógica en **4 funciones** que se encadenan con **|>**:

```
1 datos |>
2   specify() |> # 1. ¿Qué variable(s) me interesan?
3   hypothesize() |> # 2. ¿Cuál es la hipótesis nula?
4   generate() |> # 3. Simular datos bajo  $H_0$ 
5   calculate() # 4. Calcular el estadístico en cada simulación
```

specify() y hypothesize()

specify() — ¿Qué quiero analizar?

Define la variable de interés y, para proporciones, cuál es el “éxito”:

```
1 # Una proporción
2 gss |>
3   specify(response = college,
4           success = "degree")
5
6 # Una media
7 gss |>
8   specify(response = hours)
9
10 # Relación entre dos variables
11 gss |>
12   specify(age ~ partyid)
```

Argumento	¿Cuándo?
response	Siempre
success	Si response es categórica (proporción)
explanatory	Si hay una segunda variable

hypothesize() — ¿Cuál es H_0 ?

Declara la hipótesis nula. Solo tiene **un argumento** (**null**) con dos opciones:

```
1 # H0: la proporción es 0.30
2 gss |>
3   specify(response = college,
4           success = "degree") |>
5   hypothesize(null = "point", p = 0.30)
6
7 # H0: no hay relación entre variables
8 gss |>
9   specify(college ~ partyid,
10          success = "degree") |>
11   hypothesize(null = "independence")
```

null =	Significado	Parámetro extra
"point"	El valor es X	p, mu, med, sigma
"independence"	No hay relación	—


`generate()` y `calculate()`

Resumen **infer**

infer implementa la inferencia en **pasos ordenados** que se leen como una receta:

Función	¿Qué hace?
<code>specify()</code>	Define la variable de respuesta y el “éxito”
<code>generate()</code>	Genera las remuestras (bootstrap)
<code>calculate()</code>	Calcula el estadístico en cada remuestra
<code>get_confidence_interval()</code>	Construye el intervalo de confianza
<code>visualise()</code>	Grafica la distribución

Resumen infer



Paso 1: `specify()`

Especificamos cuál es la variable y qué valor es el “éxito”:

```
1 muestra |>  
2   specify(response = p_originario, success = "si")
```

Response: p_originario (factor)

A tibble: 300 × 1

p_originario
 <fct>

1 no

2 no

3 si

4 no

5 si

6 si

7 no

8 no

9 no

10 no

i 290 more rows

Esto le dice a `infer`: “voy a trabajar con la variable `p_originario` y me interesa la proporción de `si`”.

Paso 2 y 3: `generate()` + `calculate()`

Generamos 1.000 remuestras *bootstrap* y calculamos la proporción en cada una:

```
1 distribucion_bootstrap <- muestra |>
2   specify(response = p_originario, success = "si") |>
3   generate(reps = 1000, type = "bootstrap") |>
4   calculate(stat = "prop")
5
6 head(distribucion_bootstrap, 4)
```

Response: p_originario (factor)


A tibble: 4 × 2

	replicate	stat
	<int>	<dbl>
1	1	0.277
2	2	0.267
3	3	0.29
4	4	0.283

Obtenemos 1.000 valores de $\hat{p}$, uno por remuestra.

Visualizar la distribución bootstrap

```
1 distribucion_bootstrap |>  
2   visualise()
```



La distribución está **centrada en nuestro estimador** y tiene forma acampanada (aproximadamente normal).



Practiquemos: distribución bootstrap

Usando el dataset `bootstrap_props` ya cargado, complete el código para generar **500 remuestras bootstrap** de la proporción y visualícelas.

R Code

[Start Over](#)

[Run Code](#)

```
1 library(infer)
2 library(dplyr)
3
4 # Muestra de ejemplo: 250 personas, variable "respuesta" (si/no)
5 muestra_ej <- tibble(
6   respuesta = sample(c("si", "no"), 250, replace = TRUE, prob = c(0.4, 0.6))
7 )
8
9 muestra_ej |>
10   specify(response = respuesta, success = "___") |>
11   generate(reps = ___, type = "bootstrap") |>
12   calculate(stat = "___") |>
13   visualise()
```

Construir el intervalo de confianza

Un **intervalo de confianza (IC)** entrega un **rango de valores plausibles** para el parámetro. Con **infer**:

```
1 ic <- distribucion_bootstrap |>  
2   get_confidence_interval(level = 0.95, type = "percentile")  
3 ic
```


```
# A tibble: 1 × 2  
  lower_ci upper_ci  
    <dbl>    <dbl>  
1    0.237    0.34
```

El método de **percentiles** toma los percentiles 2.5 y 97.5 de la distribución bootstrap, dejando el 95% central en el medio.

Visualizar el IC

```
1 distribucion_bootstrap |>  
2   visualise() +  
3   shade_confidence_interval(endpoints = ic)
```

Simulation-Based Bootstrap Distribution



Interpretar el intervalo de confianza

Nuestro IC al 95% fue aproximadamente 0.237 a 0.34.

¿Qué significa esto?

“Con un 95% de confianza, el porcentaje real de personas que se identifican con un pueblo originario está entre el 23.7% y el 34%.”

Cuidado con la interpretación

El 95% **no** significa que hay 95% de probabilidad de que el parámetro esté en *este* intervalo. Significa que si repitiéramos el proceso muchas veces, deberíamos capturar el valor verdadero del parámetro aproximadamente el 95% de las veces.

¿Funcionó?

Recordemos que el valor **real** (que simulamos) era $p = 0.30$:

```
1 ic
```

```
# A tibble: 1 × 2  
  lower_ci upper_ci  
    <dbl>    <dbl>  
1    0.237    0.34
```



Tip

¡El intervalo **contiene** el valor real de 0.30! Esto ilustra que el método funciona: en el largo plazo, el 95% de los intervalos así contruidos capturan el verdadero parámetro.

¿Qué afecta el ancho del IC?

Nivel de confianza $\uparrow$

- ▶ Mayor confianza (99% vs 95%) $\rightarrow$ intervalo **más ancho**.
- ▶ Más exactitud, menos precisión.


Tamaño muestral (n) $\uparrow$

- ▶ Muestra más grande $\rightarrow$ intervalo **más angosto**.
- ▶ Más datos, más precisión.



Tip

Existe un *trade-off* entre **confianza** y **precisión**. Para ganar ambas a la vez, necesitamos **más datos**.





Pregunta N° 1

Un estudio estima, con un IC al 95%, que la tasa de aprobación de una política está entre **42% y 48%**.
¿Cuál interpretación es correcta?

Seleccione la opción correcta

Exactamente el 95% de las personas aprueban la política

Hay 95% de probabilidad de que el valor real esté en este intervalo específico

Si repitiéramos el muestreo muchas veces, el 95% de los intervalos contendrían el valor real

El valor real es necesariamente 45% (el punto medio)

Revisar

Reiniciar

Ejercicio Guiado

En la **guía de ejercicios** construiremos un IC paso a paso con datos reales del Censo:

1. Calcular la proporción poblacional y la de una muestra.
2. Generar 1.000 remuestras *bootstrap* con **infer**.
3. Construir el IC con los métodos de **percentiles** y **error estándar**.
4. Verificar si el IC contiene el valor real del parámetro.

Pruebas de hipótesis

La lógica de una prueba de hipótesis

- ▶ Una **prueba de hipótesis** evalúa si los datos son **compatibles** con una afirmación sobre la población.
- ▶ Funciona como un **juicio**: asumimos la “inocencia” (hipótesis nula) y vemos si la evidencia (los datos) es suficiente para rechazarla.



Tip

La pregunta clave es: “¿qué tan sorprendentes serían nuestros datos **si** la hipótesis nula fuera cierta?”

Hipótesis nula y alternativa

	Símbolo	¿Qué afirma?
Hipótesis nula	H_0	No hay efecto / el valor es el esperado. “ <i>Status quo</i> ”
Hipótesis alternativa	H_A	Sí hay efecto / el valor es distinto

Ejemplo: El Ministerio del Trabajo afirma que el **80%** de los beneficiarios de un programa de capacitación encuentra empleo dentro de los seis meses posteriores a su egreso. Un investigador selecciona aleatoriamente 200 egresados para evaluar la efectividad del programa.

- ▶ $H_0 : p = 0.80$ (el Ministerio tiene razón)
- ▶ $H_A : p \neq 0.80$ (la proporción real es distinta)

El p-value

Nota

El **p-value** es la probabilidad de observar un resultado **tan extremo o más extremo** que el observado en la muestra, **suponiendo que** la hipótesis nula (H_0) es verdadera.

- ▶ **p-value pequeño** (< 0.05): los datos observados serían muy raros (poco probables) si H_0 fuera verdadera → Existe evidencia suficiente para **rechazar** H_0 .
- ▶ **p-value grande** (≥ 0.05): los datos observados son compatibles con H_0 → **No** existe **evidencia suficientes** para rechazar H_0 .

El umbral (ej. 0.05) se llama **nivel de significancia** (α) y se fija **antes** de ver los datos.

Ejemplo: Programa de capacitación del Ministerio del Trabajo

De 200 egresados, 146 estaban empleados:

```
1 datos_mintrab <- tibble(  
2   empleo6m = c(rep("ocupado", 146), rep("desocupado", 54))  
3 )  
4  
5 p_hat <- datos_mintrab |>  
6   specify(response = empleo6m, success = "ocupado") |>  
7   calculate(stat = "prop")  
8 p_hat
```

Response: empleo6m (factor)

A tibble: 1 × 1

```
  stat  
  <dbl>  
1  0.73
```

Observamos $\hat{p} = 0.73$. El Ministerio afirma $p = 0.80$. ¿Es 0.73 lo suficientemente lejos de 0.80 para rechazar su afirmación?

Simular el “mundo de H_0 ” con **infer**

Generamos la **distribución nula**: cómo se vería $\hat{p}$ en muchas muestras **si realmente** $p = 0.80$:

```
1 distribucion_nula <- datos_mintrab |>
2   specify(response = empleo6m, success = "ocupado") |>
3   hypothesise(null = "point", p = 0.80) |>
4   generate(reps = 1000, type = "draw") |>
5   calculate(stat = "prop")
6
7 head(distribucion_nula, 3)
```

Response: empleo6m (factor)

Null Hypothesis: point


A tibble: 3 × 2

	replicate	stat
	<int>	<dbl>
1	1	0.795
2	2	0.81
3	3	0.785

La novedad es **hypothesise()**: le decimos a **infer** que simule un mundo donde H_0 es cierta.

Visualizar el p-value

```
1 distribucion_nula |>  
2   visualise(bins = 15) +  
3   shade_p_value(obs_stat = p_hat, direction = "both")
```



El área sombreada (las dos colas) es el **p-value**: qué tan probable es obtener un valor tan extremo como 0.73 si $p = 0.80$.

Calcular el p-value y decidir

```
1 p_value <- distribucion_nula |>
2   get_p_value(obs_stat = p_hat, direction = "both")
3 p_value
```

```
# A tibble: 1 × 1
  p_value
  <dbl>
1    0.024
```

```
1 p_value < 0.05
```

```
      p_value
[1,]    TRUE
```



Tip

Como el p-value es **menor que 0.05**, **rechazamos** H_0 : la evidencia sugiere que la proporción real de egresados con empleo a los 6 meses de haber terminado la capacitación **no es** el 80% que afirma el Ministerio del Trabajo.



Practiquemos: prueba de hipótesis

Una moneda se lanza 100 veces y sale cara 60 veces. ¿Es justa ($p = 0.5$)? Complete el código:

R Code

↺ Start Over

▶ Run Code

```
1 library(infer)
2 library(dplyr)
3
4 lanzamientos <- tibble(
5   resultado = c(rep("cara", 60), rep("sello", 40))
6 )
7
8 p_hat <- lanzamientos |>
9   specify(response = resultado, success = "cara") |>
10  calculate(stat = "prop")
11
12 lanzamientos |>
13   specify(response = resultado, success = "cara") |>
14   hypothesise(null = "point", p = ___) |>
15   generate(reps = 1000, type = "draw") |>
16   calculate(stat = "prop") |>
17   get_p_value(obs_stat = ___, direction = "both")
```

Conexión entre IC y prueba de hipótesis

Las dos herramientas están conectadas:

Si un **IC al 95% no contiene** el valor de H_0 , entonces rechazaríamos H_0 a un nivel de significancia del 5%.

En el ejemplo anterior, el IC al 95% fue aproximadamente $[0.67, 0.79]$. Como **no contiene** el 0.80 del Ministerio del Trabajo, llegamos a la **misma conclusión**: rechazamos H_0 .

```
1 between(0.80, 0.67, 0.79) # ¿El 0.80 está dentro del IC?
```

```
[1] FALSE
```




Pregunta N° 2

Realizamos una prueba de hipótesis con $\alpha = 0.05$ y obtenemos un **p-value de 0.12**. ¿Qué concluimos?

Seleccione la opción correcta

Rechazamos H_0 porque el p-value es positivo

No rechazamos H_0 porque el p-value (0.12) es mayor que 0.05

Probamos que H_0 es verdadera

El resultado no es válido porque el p-value debe ser menor a 0.05

Revisar

Reiniciar

Errores de decisión

Errores Tipo I y Tipo II

Como decidimos bajo incertidumbre, podemos equivocarnos de dos formas:

	H_0 es verdadera	H_0 es falsa
Rechazamos H_0	 Error Tipo I (α)	 Decisión correcta
No rechazamos H_0	 Decisión correcta	 Error Tipo II (β)

- ▶ **Error Tipo I:** rechazar H_0 cuando era verdadera (*falso positivo*).
- ▶ **Error Tipo II:** no rechazar H_0 cuando era falsa (*falso negativo*).

Una analogía: el juicio

En un juicio, H_0 = “el acusado es inocente”:

Error Tipo I ✖

Condenar a un **inocente**.

(Rechazamos la inocencia cuando era verdadera)

Error Tipo II ✖

Liberar a un **culpable**.

(No rechazamos la inocencia cuando era falsa)



Tip

El nivel de significancia α (ej. 0.05) es precisamente la probabilidad que estamos dispuestos a aceptar de cometer un **error tipo I**. Por eso lo fijamos bajo.



Pregunta N° 3

Un test médico tiene como H_0 : “el paciente está sano”. El test concluye que la persona está enferma, pero en realidad **estaba sana**. ¿Qué tipo de error se cometió?

Seleccione la opción correcta

Error Tipo I (falso positivo)

Error Tipo II (falso negativo)

No se cometió ningún error

Ambos errores simultáneamente

Revisar

Reiniciar

Recapitulación

¿Qué aprendimos hoy?

Concepto	Idea clave
Parámetro vs estimador	p (desconocido) se estima con $\hat{p}$ (de la muestra)
Bootstrap	Remuestrear con reemplazo para simular la variabilidad
Intervalo de confianza	Rango de valores plausibles para el parámetro
Hipótesis	H_0 (status quo) vs H_A (hay efecto)
p-value	Probabilidad de un resultado tan extremo si H_0 es cierta
Errores	Tipo I (falso positivo, α) y Tipo II (falso negativo, β)

El flujo de **infer**

```
1 # Intervalo de confianza
2 muestra |>
3   specify(response = var, success = "si") |>
4   generate(reps = 1000, type = "bootstrap") |>
5   calculate(stat = "prop") |>
6   get_confidence_interval(level = 0.95)
7
8 # Prueba de hipótesis
9 muestra |>
10  specify(response = var, success = "si") |>
11  hypothesise(null = "point", p = 0.8) |>
12  generate(reps = 1000, type = "draw") |>
13  calculate(stat = "prop") |>
14  get_p_value(obs_stat = p_hat, direction = "both")
```

La próxima clase usaremos estos conceptos para la **regresión lineal**.

Bibliografía

- Bruce, Peter C., Andrew Bruce, y Peter Gedeck. 2020. *Practical statistics for data scientists: 50+ essential concepts using R and Python*. Second edition. Beijing Boston Farnham Sebastopol Tokyo: O'Reilly.
- Çetinkaya-Rundel, Mine, y Johanna Hardin. 2024. *Introduction to modern statistics*. 2e ed. Vereinigte Staaten: OpenIntro, Inc. <https://openintro-ims.netlify.app/>.
- Ismay, Chester, Albert Y. Kim, y Arturo Valdivia. 2025. *Statistical inference via data science: a ModernDive into R and the Tidyverse*. Second edition. The R series. Boca Raton London New York: CRC Press Taylor & Francis Group. <https://moderndive.com/>.