

Clase 6: Regresión Lineal Simple

Análisis de Datos y Estadística Computacional

Prof. Gabriel Duarte Zúñiga

Universidad Adolfo Ibáñez | DIAPP-2026

4 de julio de 2026

¡Bienvenid@s a la Clase 6!

Objetivos Clase 6

En esta clase aprenderemos a **estimar** cuantitativamente la relación entre dos variables usando un modelo de **regresión lineal simple**. Los modelos de regresión lineal son una de las herramientas fundamentales dentro de la econometría aplicada.

Los objetivos específicos de esta clase son:

- ▶ Entender el proceso de ir de una **pregunta de interés** a un **modelo econométrico**.
- ▶ Estimar una regresión con `lm()` e interpretar sus resultados.
- ▶ Comprender por qué el método de estimación de Mínimos Cuadrados Ordinarios (**MCO u OLS en inglés**) tiene propiedades deseables y cuáles son las condiciones que lo aseguran (Teorema Gauss-Markov).
- ▶ Interpretar coeficientes β , R^2 y significancia estadística.
- ▶ Distinguir **correlación** de **causalidad**.

De la pregunta al modelo

¿Qué es la econometría?

- ▶ La econometría desarrolla métodos estadísticos para **estimar relaciones económicas, probar teorías y evaluar e implementar políticas públicas** mediante datos ([Wooldridge 2020](#)).
- ▶ Algunas preguntas que la econometría puede ayudar a responder:
 - ¿Cuál es el retorno salarial de un año más de educación?
 - ¿Qué efecto tiene un aumento del salario mínimo sobre el empleo?
 - ¿Un aumento de la dotación policial reduce los delitos?

Aclaración importante

A diferencia de los **experimentos controlados**, la econometría trabaja principalmente con **datos observacionales**, en donde el investigador **no controla** la asignación de las variables. Una de las implicancias de esto, es que para distinguir entre asociaciones de variables y causalidad, se requieren métodos econométricos específicos.

De la pregunta al modelo: 3 pasos

Para aplicar un modelo econométrico y extraer conclusiones de la relación entre las variables de un conjunto de datos, es recomendable seguir los siguientes pasos:

1. Formular la pregunta de interés:

Ej: ¿Cuál es el efecto de un año adicional de educación en el salario de una persona?

2. Especificar un modelo econométrico: Una vez definida la pregunta de interés, es importante pensar en las variables que permiten la relación y estimación del objetivo de estudio

$$wage = \beta_0 + \beta_1 \cdot educ + u$$

Donde u recoge todo lo que **no observamos** (habilidad, motivación, etc.).

3. Estimar el modelo con datos y contrastar hipótesis.

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

Resumen

El orden recomendado para iniciar una investigación cuantitativa empírica es: **pregunta** → **modelo** → **datos** → **estimación** → **interpretación**.

Tipos de datos


Tipo	Descripción	Ejemplo
Corte transversal	Observaciones en un momento del tiempo	Encuesta CASEN 2024
Serie de tiempo	Una unidad observada en múltiples períodos	PIB trimestral de Chile
Corte transversal combinado	Muestras distintas en distintos períodos	CASEN 2022 + 2024
Panel (longitudinal)	Las mismas unidades seguidas en el tiempo	Estudio Longitudinal Social de Chile (ELSOC)

Tipos de datos

Tipos de datos en econometría (Wooldridge)

Los cuatro formatos de datos más comunes en análisis econométrico


1 Corte transversal



- Descripción:**
Observaciones en un momento del tiempo
- Ejemplo:**
Encuesta CASEN 2024

muchas unidades, 1 período

2 Serie de tiempo



- Descripción:**
Una unidad observada en múltiples períodos
- Ejemplo:**
PIB trimestral de Chile

1 unidad, muchos períodos


3 Corte transversal combinado



- Descripción:**
Muestras distintas en distintos períodos
- Ejemplo:**
CASEN 2022 + 2024

muestras distintas, varios períodos

4 Panel (longitudinal)



- Descripción:**
Las mismas unidades seguidas en el tiempo
- Ejemplo:**
Estudio Longitudinal Social de Chile (ELSOC)

mismas unidades, varios períodos



Idea clave: la diferencia principal entre estos formatos está en cuántas unidades observamos y cómo las seguimos a través del tiempo.

Elaborado con IA en función de la tabla resumen en base a ([Wooldridge 2020](#))

Nota

En este curso trabajaremos principalmente con datos de **corte transversal**. Una de sus ventajas es que, bajo ciertas condiciones, podemos asumir que los datos fueron obtenidos mediante un **muestreo aleatorio**.

Dataset de ejemplo: **wage1** (Wooldridge 2020)

526 trabajadores estadounidenses con información sobre salario, educación, experiencia y características demográficas:

```
1 data(wage1)
2 glimpse(wage1)
```

Rows: 526

Columns: 24

```
$ wage      <dbl> 3.10, 3.24, 3.00, 6.00, 5.30, 8.75, 11.25, 5.00, 3.60, 18.18,...
$ educ      <int> 11, 12, 11, 8, 12, 16, 18, 12, 12, 17, 16, 13, 12, 12, 12, 16...
$ exper     <int> 2, 22, 2, 44, 7, 9, 15, 5, 26, 22, 8, 3, 15, 18, 31, 14, 10, ...
$ tenure    <int> 0, 2, 0, 28, 2, 8, 7, 3, 4, 21, 2, 0, 0, 3, 15, 0, 0, 10, 0, ...
$ nonwhite  <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ female    <int> 1, 1, 0, 0, 0, 0, 0, 1, 1, 0, 1, 1, 0, 0, 0, 0, 1, 1, 1, 1, 1...
$ married   <int> 0, 1, 0, 1, 1, 1, 0, 0, 0, 1, 0, 0, 1, 0, 1, 1, 1, 0, 1, 1, 0...
$ numdep    <int> 2, 3, 2, 0, 1, 0, 0, 0, 2, 0, 0, 0, 2, 0, 1, 1, 0, 0, 3, 0, 0...
$ smsa      <int> 1, 1, 0, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
$ northcen  <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ south     <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ west      <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
$ construc  <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ ndurman   <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ trcommpu  <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ trade     <int> 0 0 1 0 0 0 1 0 1 0 1 0 0 0 0 0 0 0 0 0 0
```


Variables principales de **wage1**

Variable	Descripción
wage	Salario por hora (USD de 1976)
educ	Años de educación formal
exper	Años de experiencia laboral
tenure	Años en el empleo actual
female	1 si es mujer, 0 si es hombre
nonwhite	1 si no es blanco, 0 si es blanco
lwage	Logaritmo natural del salario

Exploración visual

¿Se ve una relación entre educación y salario?


```
1 ggplot(wage1, aes(x = educ, y = wage)) +  
2   geom_point(alpha = 0.4, color = "steelblue") +  
3   labs(x = "Años de educación", y = "Salario por hora (USD)") +  
4   theme_classic(base_size = 14)
```



Parece haber una tendencia positiva, pero con mucha dispersión. ¿Podemos **cuantificar** esa relación?

Exploración visual

Si ajustamos una recta se ve más clara la relación, pero ¿cómo obtenemos esta recta?




La recta de mejor ajuste: MCO

Ecuación de la recta

- ¿Recuerdan la ecuación de la recta que vieron en clases de matemáticas?

$$y = mx + n$$

donde m es la pendiente de la recta y b es el intercepto (donde corta la recta en el eje **y**). Por ejemplo:



$$y = 2x + 1$$

con $m = 2$ y $n = 1$

Una comparación útil

Clase de **matemáticas**:

- ▶ $y = n + mx$
- ▶ n es el intercepto en el eje
- ▶ m es la pendiente

- ▶ $\hat{\beta}_0$ y $\hat{\beta}_1$ se conocen también como coeficientes de regresión y serán nuestros **parámetros a estimar**.
- ▶ $\hat{y}$ lo denominamos como los **valores ajustados**, o bien, los valores estimados por nuestra función para cada valor posible de x .

Clase de **econometría**:

- ▶ $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\mu}$
- ▶ $\hat{\beta}_0$ es el intercepto en el eje x
- ▶ $\hat{\beta}_1$ es la pendiente
- ▶ $\hat{u}$ es el residuo o la diferencia entre lo observado y lo estimado: $\hat{u} = y_i - \hat{y}_i$

Definición del modelo de regresión simple

Si contamos con dos variables (x e y) y estamos interesados en **explicar** y en términos de x , o bien, como varía y cuando x cambia, un modelo de regresión lineal simple nos puede ayudar a formalizar el planteamiento de este problema matemáticamente y estimar un parámetro (β_1) que describa esta relación:

$$y = \beta_0 + \beta_1 x + \mu$$

Donde β_0 es el intercepto, β_1 la pendiente y μ el término de error que representa todos los factores distintos de x que afectan a y . En este sentido, el término de error (μ) también se conoce como *inobservable*.

- Notar que el modelo de regresión anterior es un **modelo poblacional** o **teórico**: describe la relación entre x e y en la población. Sin embargo, en la práctica no conocemos los valores reales de β_0 ni de β_1 , por lo que debemos estimarlos.

Valores predichos $\hat{y}$ y residuos $\hat{u}$

- En la práctica, dado que solo observamos una muestra de datos, estimamos una recta que describa nuestra “*mejor predicción*” para y dado los valores de x . Asumiendo que $E(\mu) = 0$ y que $Cov(x, \mu) = 0$ tenemos que:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

donde $\hat{y}$ representa el valor de y **predicho o ajustado** por el modelo para cada valor de x .

- Algo similar ocurre con el **error** y el **residuo**. En el modelo poblacional, μ representa el error verdadero, es decir, todos los factores no observados que afectan a y . Pero como no conocemos la relación verdadera, tampoco observamos directamente μ , mientras que en la muestra, lo que sí podemos calcular es el **residuo**:

$$\hat{u} = y - \hat{y}$$

Es decir, el residuo mide cuánto se “equivoca” la recta estimada al predecir cada observación.

En simple

y es el valor observado, mientras que $\hat{y}$ es el valor que predice la recta estimada. Por otro lado, μ es el error verdadero pero no observable; $\hat{u}$ es el error que observamos después de estimar el modelo, es decir, la diferencia entre el dato real y lo que predice la recta.


¿Cómo estimamos la mejor recta?

Podríamos trazar infinitas rectas a través de la nube de puntos, cuya pendiente sería una estimación de la relación entre y y x . El método de mínimos cuadrados ordinarios (MCO u OLS) elige la que **minimiza la suma de los residuos al cuadrado**:

$$\min \sum_{i=1}^n \hat{u}_i^2 = \min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Residuos de manera visual


OLS minimiza la suma de estos segmentos al cuadrado



Los segmentos rojos son los **residuos** ($\hat{u}_i$): la distancia entre cada punto observado ($\bullet$) y su valor predicho sobre la recta ($\circ$).

¿Por qué esa pendiente y no otra?

Una forma alternativa de entender MCO es pensar que este método **prueba todas las rectas posibles** y elige la que produce la **menor suma de residuos al cuadrado (SSR)**. Observemos cómo cambia la suma de residuos al cuadrado (SSR) a medida que la recta ajustada varía:



💡 En simple

La recta se “estabiliza” en la pendiente que **minimiza** la SSR. Cualquier otra recta produce una suma de residuos al cuadrado más grandes.

Modelo de Regresión Lineal Simple (Resumen)

Objetivo: El modelo de regresión simple puede utilizarse para estudiar la **relación entre dos variables**.

- ▶ Si queremos explicar una variable y en términos de x , es decir, analizar cómo varía y cuando varía x , el siguiente modelo de regresión puede ayudarnos a realizarlo ([Heiss 2020](#)):

$$y = \beta_0 + \beta_1 x + \mu$$

- ▶ Se llama *simple* porque solo buscamos explicar y a través de **una sola variable** x . Si utilizamos más variables explicativas (2 o más) lo llamaremos **modelo de regresión múltiple**.
- ▶ **Estimador de β_0 :**

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- ▶ **Estimador de β_1 :** Corresponde a la covarianza dividido en la varianza de x

$$\hat{\beta}_1 = \rho_{xy} \times \left(\frac{\sigma_y}{\sigma_x} \right) = \frac{Cov(x, y)}{Var(x)}$$

- ▶ **¿Cómo lo implementamos en R?:** Utilizando la función `lm(.)` (linear model del paquete `stats` que viene cargado por defecto).

Primera regresión en R

- ▶ Para estimar los parámetros de una regresión lineal mediante MCO utilizamos la función `lm()` (linear model), especificando al menos los siguientes argumentos:
 - **formula:** Para especificar la variable dependiente y junto con la o las variable(s) explicativa(s) x debemos escribir: `y~x`.
 - **data:** debemos indicar el nombre del objeto o dataset sobre el cual haremos la regresión (importante fijarse en el formato en que se encuentre)
- ▶ Con la función `summary()` podemos imprimir un resumen de los principales resultados de la regresión:

Primera regresión en R

```
1 modelo1 <- lm(wage ~ educ, data = wage1)
2 summary(modelo1)
```

Call:

```
lm(formula = wage ~ educ, data = wage1)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.3396	-2.1501	-0.9674	1.1921	16.6085

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.90485	0.68497	-1.321	0.187
educ	0.54136	0.05325	10.167	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.378 on 524 degrees of freedom

Multiple R-squared: 0.1648, Adjusted R-squared: 0.1632

F-statistic: 103.4 on 1 and 524 DF, p-value: < 2.2e-16

¿Qué Tipo de Objeto Entrega `lm`?

```
1 reg_mtcars <- lm(hp ~ mpg, data = mtcars)
2 names(reg_mtcars)
```


```
[1] "coefficients" "residuals"      "effects"        "rank"
[5] "fitted.values" "assign"          "qr"             "df.residual"
[9] "xlevels"      "call"           "terms"          "model"
```

- `lm` entrega una **lista** de objetos que guardan distintos valores. En particular, los objetos que más nos interesan son los siguientes:
 - **coefficients:** Representa los coeficientes estimados de la regresión. Se pueden extraer con la función `coef(reg_mtcars)`
 - **residuals:** Entrega los residuos de la estimación. Se pueden extraer con la función `resid(reg_mtcars)`
 - **fitted.values:** Representa los valores predichos (las estimaciones en la variable dependiente) que conforman la recta de regresión. Se pueden extraer con la función `fitted(reg_mtcars)`

¿Cómo se visualiza lo anterior?

Ahora entendemos de dónde proviene la recta que estimamos en la clase 3 con `geom_smooth(method = 'lm')`:

```
1 ggplot(mtcars, aes(x = mpg, y = hp))+  
2   geom_point()+  
3   geom_smooth(method = 'lm', se = F)+ #lm de 'linear model'  
4   theme_classic()
```



¿Cómo resumir en una tabla los resultados?

Esto se puede hacer de varias formas, pero por ahora veremos 4:

1. Con la función `summary()` (paquete base). Esta es la más básica y resume los valores más importantes al momento de analizar los resultados de una regresión
2. Con la función `tidy()` del paquete `broom`. Esto permite generar un tabla de resultados en formato tidy como hemos visto en clases anteriores del parámetro estimado, su error estándar, su estadístico t y su valor-p
3. Con la función `glance()` también del paquete `broom`. Esta función entrega otras estadísticas que son interesantes de analizar como el R^2 que explicaremos más adelante.
4. Con la función `get_regression_table()` del paquete `moderndive`. Está basada en la función `tidy` pero agrega más información relevante para el análisis

¿Cómo interpretar los resultados de los coeficientes?

- ▶ **Estimate:** Los coeficientes estimados para cada variable. Indican la cantidad de cambio en la variable de respuesta por unidad de cambio en la variable predictora, manteniendo constantes otras variables (*ceteris paribus*).
- ▶ **Std. Error:** El error estándar del coeficiente. Proporciona una medida de la variabilidad de la estimación del coeficiente.
- ▶ t value: El valor t para la prueba de hipótesis de que el coeficiente es **igual a cero**. Se calcula como el coeficiente dividido por su error estándar.
- ▶ $Pr(> |t|)$: El p-valor asociado con el valor t . Indica la probabilidad de observar un valor t tan extremo como el observado (o más extremo) si la hipótesis nula es **verdadera**.

¿Cómo interpretar los valores-p?

- ▶ **Significancia (Asteriscos):** Los asteriscos junto a los p-valores indican el nivel de significancia:
 - *******: $p < 0.001$
 - ******: $p < 0.01$
 - *****: $p < 0.05$
 - **.**: $p < 0.1$
 - **Sin asterisco**: $p \geq 0.1$
- ▶ Los asteriscos son una forma rápida de identificar qué variables son estadísticamente significativas en el modelo.

En simple

Generalmente lo que buscamos es al hacer inferencia sobre los parámetros estimados es **rechazar la hipótesis nula**. Con valores-p **pequeños** (ej $< .05$), **rechazamos** la hipótesis nula de que el parámetro estimado es igual a 0. Con valores-p **grandes** (ej $> .05$)), **no se puede rechazar** la hipótesis nula, por lo que **no** se cuenta con evidencia estadística suficiente de un efecto de la variable x sobre y .

Extraer resultados con **broom**

El paquete **broom** convierte la salida de `lm()` en tibbles ordenados:

tidy() — coeficientes

```
1 tidy(modelo1)
```

A tibble: 2 × 5

term	estimate	std.error	statistic
p.value			
<chr>	<dbl>	<dbl>	<dbl>
<dbl>			
1 (Intercept)	-0.905	0.685	-1.32
1.87e- 1			
2 educ	0.541	0.0532	10.2
2.78e-22			

glance() — métricas del modelo

```
1 glance(modelo1)|>
2   select(r.squared, sigma, p.value, nobs)
```

A tibble: 1 × 4

	r.squared	sigma	p.value	nobs
	<dbl>	<dbl>	<dbl>	<int>
1	0.165	3.38	2.78e-22	526



Tip

`tidy()` y `glance()` transforman la salida estándar de `summary()` en tibbles que podemos manipular con **dplyr** para filtrar, graficar, y todas las funciones que vimos en la unidad I.

Interpretar los coeficientes

Del modelo $\widehat{wage} = \hat{\beta}_0 + \hat{\beta}_1 \cdot educ$:

```
1 library(moderndive)
2 get_regression_table(modelo1)
```

A tibble: 2 × 7

	term	estimate	std_error	statistic	p_value	lower_ci	upper_ci
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	intercept	-0.905	0.685	-1.32	0.187	-2.25	0.441
2	educ	0.541	0.053	10.2	0	0.437	0.646

Nota

$\hat{\beta}_1 = \mathbf{0.541}$: por cada año adicional de educación, el salario por hora aumenta en promedio **0.54 USD** (de 1976).

- $\hat{\beta}_0 = -0.905$: el salario estimado cuando **educ = 0**. En este caso no tiene una interpretación práctica útil ya que no se puede recibir un salario laboral negativo.

Unidades de medición y formas funcionales

- ▶ Cuando se multiplica la **variable dependiente** por una constante c (lo que significa multiplicar cada valor de la muestra por c), entonces las estimaciones de MCO del **intercepto** y de la **pendiente** también son multiplicadas por c .
- ▶ La bondad de ajuste (R^2) del modelo **no depende** de las unidades de medición de las variables.
- ▶ En el modelo log/nivel, $100 * \beta_1$ entrega la **semielasticidad** de y respecto a x , mientras que el $\log/\log \beta_1$ corresponde a la **elasticidad**.

A continuación se resumen la formas funcionales en donde se ocupan logaritmos y su interpretación.

Unidades de medición y formas funcionales

Modelo	Ecuación	Interpretación
Lineal-Lineal	$Y = \beta_0 + \beta X$	Un cambio de una unidad en X esta asociado con un cambio de β unidades en Y
Log-Lineal	$\log(Y) = \beta_0 + \beta X$	Un cambio de una unidad en X esta asociado con un cambio de $(100 * \beta)\%$ en Y
Lineal-Log	$Y = \beta_0 + \beta \log(X)$	Un cambio de 1% en X esta asociado con un cambio de $\frac{\beta}{100}$ unidades en Y
Log-Log	$\log(Y) = \beta_0 + \beta \log(X)$	Un cambio de 1% en X esta asociado con un cambio de $\beta\%$ en Y

A continuación, se presenta un ejemplo de interpretación con los datos *ceosa11* del paquete **wooldridge**:

Un mismo dataset, cuatro formas funcionales

Para comparar las cuatro formas funcionales usaremos `hprice1` ([Wooldridge 2020](#)): 88 viviendas con su precio de venta y superficie construida.

```
1 data(hprice1)
2 hprice1 |> select(price, sqrft, lprice, lsqrft) |> head(4)
```

	price	sqrft	lprice	lsqrft
1	300	2438	5.703783	7.798934
2	370	2076	5.913503	7.638198
3	191	1374	5.252274	7.225482
4	195	1448	5.273000	7.277938

- ▶ `price`: precio de venta, en **miles de USD**
- ▶ `sqrft`: superficie construida, en **pies cuadrados**
- ▶ `lprice`, `lsqrft`: sus logaritmos naturales, ya calculados en el dataset

1. Nivel-Nivel: ¿en cuántos USD cambia el precio?

```
1 mod_nn <- lm(price ~ sqrft, data = hprice1)
2 tidy(mod_nn)
```

```
# A tibble: 2 × 5
  term          estimate std.error statistic  p.value
<chr>         <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)   11.2       24.7       0.453 6.52e- 1
2 sqrft         0.140      0.0118     11.9  8.42e-20
```

Nota

$\hat{\beta}_1 = \mathbf{0.14}$: cada pie cuadrado adicional de construcción se asocia, en promedio, a un aumento de **\$140** en el precio de la vivienda (recordar que **price** está en miles de USD). Este efecto en dólares es el **mismo** para una casa chica que para una grande.

2. Log-Nivel: ¿en qué % cambia el precio?

```
1 mod_ln <- lm(lprice ~ sqrft, data = hprice1)
2 tidy(mod_ln)
```

```
# A tibble: 2 × 5
  term      estimate std.error statistic  p.value
<chr>      <dbl>      <dbl>      <dbl>    <dbl>
1 (Intercept) 4.82        0.0766      63.0 1.00e-73
2 sqrft      0.000402    0.0000366    11.0 4.80e-18
```

Nota

$\hat{\beta}_1 = 4^{-4}$. Multiplicando por 100, cada pie cuadrado adicional aumenta el precio en un 0.04% aprox. Como esta cifra es difícil de leer, conviene expresarla para un cambio más intuitivo de X : **cada 100 pies cuadrados adicionales** aumentan el precio en aproximadamente **4%**.

3. Nivel-Log: ¿qué pasa si X cambia en %?

```
1 mod_n1 <- lm(price ~ lsqrft, data = hprice1)
2 tidy(mod_n1)
```

```
# A tibble: 2 × 5
  term          estimate std.error statistic  p.value
<chr>         <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)  -1962.       214.      -9.15 2.43e-14
2 lsqrft        298.       28.3      10.5 3.95e-17
```

Nota

$\hat{\beta}_1 = \mathbf{297.91}$. Dividiendo por 100: un aumento de **1%** en la superficie construida se asocia a un aumento de **\$2.979** en el precio de la vivienda. Este modelo es útil cuando esperamos que **cambios porcentuales similares en X** (y no cambios de una unidad) produzcan efectos parecidos en Y .

4. Log-Log: la elasticidad

```
1 mod_ll <- lm(lprice ~ lsqrft, data = hprice1)
2 tidy(mod_ll)
```

```
# A tibble: 2 × 5
  term      estimate std.error statistic  p.value
<chr>    <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept) -0.975    0.641    -1.52 1.32e- 1
2 lsqrft      0.873    0.0846    10.3 1.05e-16
```

Nota

$\hat{\beta}_1 = 0.873$ es la **elasticidad** del precio respecto a la superficie: un aumento de **1%** en los pies cuadrados se asocia a un aumento de **0.87%** en el precio. Como es menor a 1, decimos que el precio de la vivienda es **inelástico** respecto a la superficie (aumenta menos que proporcionalmente).



Pregunta N° 1

Estimamos `lm(wage ~ educ)` y obtenemos $\hat{\beta}_1 = 0.54$. ¿Cuál es la interpretación correcta?

Selecione la opción correcta

Las personas con más educación ganan \$0.54 USD más que las que no tienen educación

Por cada año adicional de educación, el salario por hora aumenta en promedio \$0.54 USD

El 54% de la variabilidad del salario se explica por la educación

Si una persona estudia 0.54 años más, su salario se duplica

Revisar

Reiniciar



Ejercicio Aplicado 1: Coeficientes estimados

Usando `gapminder` (año 2007), estime la relación entre la esperanza de vida (`lifeExp`) como variable dependiente y el PIB per cápita (`gdpPerCap`) como variable explicativa. ¿Cuánto **aumenta** la esperanza de vida por cada \$1.000 USD adicionales de PIB per cápita?

R Code

↺ Start Over

▶ Run Code

```
1 library(gapminder)
2 library(dplyr)
3 library(broom)
4
5 gap_2007 <- gapminder |> filter(year == 2007)
6
7 modelo <- lm(____ ~ ____, data = gap_2007)
8
9 # Coeficientes
10 tidy(modelo)
11
12 # Hint:  $\beta_1$  está en unidades de 1 USD.
13 # Para interpretarlo por cada $1.000, multiplique por 1000.
```

Bondad de ajuste: R^2

- ▶ La bondad de ajuste es una medida que permite resumir qué tan bien el modelo de regresión describe los datos observados, es decir, qué tan bien la variable x explica a la variable dependiente y .
- ▶ El R^2 indica qué **proporción de la variabilidad** de Y es explicada por el modelo.
- ▶ Va de 0 (no explica nada) a 1 (explica toda la variabilidad).
- ▶ En R podemos acceder de manera rápida a este valor con la función `glance()`:

```
1 glance(modelo1)$r.squared # Recordar que modelo 1: lm(wage ~ educ, data = wage1)
```

```
[1] 0.1647575
```

Nota

Un R^2 de 0.165 significa que la educación por sí sola explica solo el **16.5%** de la variabilidad del salario. El resto se debe a otros factores no incorporados al modelo (experiencia, sector, habilidades, etc.).

Advertencia

Un R^2 bajo **no** significa que el modelo sea inútil. Significa que hay muchos otros factores que influyen en Y . En ciencias sociales, R^2 de 0.10–0.30 pueden seguir siendo útiles.

Bondad de Ajuste

Para entender matemáticamente cómo se calcula el R^2 tenemos que considerar las siguientes medidas:

1. **Suma Total de Cuadrados (STC o SST):** Es una medida de la variación muestral total en la variable dependiente y_i , es decir, mide qué tan dispersos están las y_i en la muestra:

$$\sum_{i=1}^n (y_i - \bar{y}_i)^2 = (n - 1) * var(y)$$
 2. **Suma Explicada de Cuadrados (SEC o SSE):** Mide la variación muestral de los valores predichos $\hat{y}_i$: $\sum_{i=1}^n (\hat{y}_i - \bar{y}_i)^2 = (n - 1) * var(\hat{y})$
 3. **Suma Residual de Cuadrados (SRC SSR):** Mide la variación muestral de los residuos $\hat{y}_i$:

$$\sum_{i=1}^n (\hat{\mu}_i - \bar{y}_i)^2 = (n - 1) * var(\hat{\mu})$$
- ▶ La variación total de y puede expresarse como la suma de la variación explicada más la variación no explicada SRC: $STC = SEC + SRC$
 - ▶ De esta manera, el R^2 queda definido como:

$$R^2 \equiv \frac{SEC}{STC} = 1 - \frac{SRC}{STC}$$

Cálculo del R^2

- Veamos el de nuestra regresión realizada para `modelo1` con el dataset de `wage1`

```
1 summary(modelo1)$r.squared
```

```
[1] 0.1647575
```

```
1 glance(modelo1) |>  
2   select(1) #Otra forma de acceder rápidamente al R2
```

```
# A tibble: 1 × 1  
  r.squared  
    <dbl>  
1    0.165
```

Cálculo del R^2


- Si lo calculamos manualmente, podemos utilizar lo que ya sabemos que representa:

```
1 var(fitted(modelo1)) / var(wage1$wage ) #Varianza de y_gorro sobre varianza de y
```

```
[1] 0.1647575
```

Recap: Visualizar la regresión

```
1 ggplot(wage1, aes(x = educ, y = wage)) +  
2   geom_point(alpha = 0.4, color = "steelblue") +  
3   geom_smooth(method = "lm", se = TRUE, color = "red4") +  
4   labs(x = "Años de educación", y = "Salario por hora (USD)",  
5         title = "Regresión simple: wage ~ educ") +  
6   theme_classic(base_size = 14)
```



¿Por qué confiar en OLS?

Propiedades de MCO (Teorema Gauss-Markov)

Si se cumplen ciertos supuestos, MCO tiene las **mejores propiedades** que podemos pedir para un estimador lineal:

Teorema de Gauss-Markov

Entre todos los estimadores que son **lineales** e **insesgados**, MCO es el que tiene la **menor varianza** (*Best Linear Unbiased Estimator*).

En español: OLS no solo le “*apunta*” en promedio al valor correcto (es **insesgado**), sino que además es el que “*apunta*” con la **menor dispersión** posible (es **eficiente**).

Los 5 supuestos de Gauss-Markov

#	Supuesto	¿Qué significa en simple?
SLR.1	Linealidad en parámetros	La relación puede escribirse como $y = \beta_0 + \beta_1 x + u$
SLR.2	Muestreo aleatorio	Los datos fueron obtenidos aleatoriamente de la población
SLR.3	Variación en X	La variable explicativa no es constante (ej: hay variación en educ)
SLR.4	Media condicional cero	$E(u x) = 0$: los factores no observados no están correlacionados con X
SLR.5	Homocedasticidad	$Var(u x) = \sigma^2$: la dispersión del error es la misma para todos los valores de X

Advertencia

El supuesto **más difícil** de cumplir en la práctica es el **SLR.4**: si hay variables omitidas que afectan tanto a Y como a X , el coeficiente $\hat{\beta}_1$ estará **sesgado**. Esto se llama **sesgo de variable omitida** y es uno de los problemas centrales de la econometría.

Recap: Inferencia sobre los coeficientes

En la Clase 5 vimos cómo interpretar intervalos de confianza, valores-p y realizar pruebas de hipótesis. Ahora aplicamos la misma lógica a los coeficientes de la regresión:

- ▶ $H_0 : \beta_1 = 0 \rightarrow$ la educación **no** tiene efecto sobre el salario.
- ▶ $H_A : \beta_1 \neq 0 \rightarrow$ la educación **sí** tiene efecto.

```
1 tidy(modelo1, conf.int = TRUE) |>
2   select(term, estimate, std.error, p.value, conf.low, conf.high)
```

A tibble: 2 × 6

	term	estimate	std.error	p.value	conf.low	conf.high
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	(Intercept)	-0.905	0.685	1.87e- 1	-2.25	0.441
2	educ	0.541	0.0532	2.78e-22	0.437	0.646

¿Es el efecto significativo?

```
1 (p_val <- tidy(modelo1)$p.value[2])
```

```
[1] 2.782599e-22
```

- ▶ El **p-value** de **educ** es 2.782599e-22, mucho menor que 0.05.
- ▶ El **IC al 95%** para β_1 es [0.44, 0.65], que **no contiene el cero**.



Tip

Ambos métodos (p-value < 0.05 e IC que no incluye 0) llevan a la **misma conclusión**: rechazamos H_0 y concluimos que la educación tiene un efecto **estadísticamente significativo** sobre el salario.



Pregunta N° 2

Un modelo arroja $\hat{\beta}_1 = 0.32$ con un p-value de 0.18. ¿Qué concluimos sobre el efecto de X sobre Y ?

Selecione la opción correcta

El efecto es significativo porque el coeficiente es positivo

No podemos rechazar H_0 : el efecto no es estadísticamente significativo al 5%

El efecto es exactamente 0.32 en la población

Debemos cambiar el nivel de significancia a 0.20 para que sea significativo

Revisar

Reiniciar



Ejercicio aplicado 2: Interpretar la salida

Dado el siguiente output, identifique: el coeficiente de **exper**, su p-value, y si es significativo al 5%.
¿Cuánto aumenta el salario por cada año adicional de experiencia?

R Code

[Start Over](#)

[Run Code](#)

```
1 library(wooldridge)
2 library(broom)
3
4 data(wage1)
5 modelo_exper <- _____(wage ~ exper, data = wage1)
6
7 # Extraiga los coeficientes con IC (con la función del paquete moderndive)
8 _____(modelo_exper)
9
10 # Extraiga R²
11 _____(modelo_exper) |> dplyr::select(r.squared, nobs)
```

Resumen sobre interpretación

- ▶ Si el valor absoluto del estadístico t es **mayor** que el valor crítico (e.g. 1.96), podemos rechazar la **hipótesis nula de que el coeficiente es igual a 0**.
- ▶ Del mismo modo, si el valor-p asociado al coeficiente es **igual o menor** que el nivel significancia definido (e.g. 5%), también rechazamos la hipótesis nula.
- ▶ Si el intervalo de confianza **no contiene el valor 0**, también podemos concluir que existe evidencia para rechazar la hipótesis nula

Ejercicio Grupal (25-30 min)

Trabajarán en **salas pequeñas** con el dataset **wage1**. Los detalles están en la **Guía de Ejercicio N° 6** disponible en webcursos.



Recuerden

- ▶ Designen a una persona que comparta pantalla.
- ▶ Intenten resolver primero y luego revisen la pauta.
- ▶ El profesor y ayudante pasarán por las salas.

**Correlación no es
causalidad**

Ceteris paribus y el contrafactual

- ▶ En la mayoría de los análisis empíricos, queremos saber si una variable tiene un **efecto causal** sobre otra: ¿cuánto cambiaría Y si **solo** cambiara X , dejando todo lo demás constante (*ceteris paribus*)? ([Wooldridge 2020](#))
- ▶ El problema central es que, para cada unidad de análisis, solo observamos **un** resultado posible conocido como **contrafactual**: nunca observamos a la misma persona simultáneamente **con** y **sin** el tratamiento.

Mundo observado: el salario de Juan **con** título universitario. **Mundo contrafactual:** el salario que **habría tenido** Juan **sin** título universitario.

(nunca lo observamos)

! El punto clave

Hacer inferencia causal **no** consiste solo en verificar un supuesto estadístico como $E(u|x) = 0$ (SLR.4). Consiste, fundamentalmente, en poder **construir un buen contrafactual**: un grupo de comparación que nos diga de forma creíble qué le habría pasado a las unidades tratadas si no hubiesen recibido el tratamiento.

Cuando el contrafactual es válido: la asignación aleatoria

La forma más creíble de construir un contrafactual es mediante un **experimento aleatorizado**: asignar el “tratamiento” (X) al azar entre las unidades, de modo que el grupo tratado y el grupo de control sean, en promedio, comparables en **todo lo demás**.

Ejemplo ([Wooldridge 2020](#)): evaluación de un programa de capacitación laboral (`jtrain2`). 445 hombres con antecedentes laborales similares fueron asignados **al azar** a un grupo de tratamiento (`train = 1`) o de control (`train = 0`), y se midieron sus ingresos en 1978 (`re78`, en miles de USD).

```
1 modelo_jtrain <- lm(re78 ~ train, data = jtrain2)
2 tidy(modelo_jtrain)
```

```
# A tibble: 2 × 5
  term          estimate std.error statistic  p.value
  <chr>          <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)    4.55      0.408      11.2  1.15e-25
2 train          1.79      0.633       2.84  4.79e- 3
```

Nota

Al asignar el tratamiento **al azar**, el grupo control se convierte en un contrafactual creíble del grupo tratado. Por eso, la diferencia de promedios (**\$1.794** más al año) sí podría interpretarse como el **efecto causal promedio** del programa.

¿Por qué correlación $\neq$ causalidad?

Con **datos observacionales** (sin aleatorización), una correlación entre X e Y puede aparecer por razones que **no** son un efecto causal de X sobre Y . Tres casos frecuentes:

1. **Coincidencia** $\rightarrow$ correlaciones *espurias* (azar o tendencias comunes).
2. **Causa común** $\rightarrow$ una tercera variable *confusora* mueve a X e Y a la vez.
3. **Causalidad inversa / simultaneidad** $\rightarrow$ en realidad Y afecta a X (o ambas se determinan mutuamente).




Tip

En los tres casos la regresión simple mide **asociación**, no causalidad. Distinguirlos requiere un buen contrafactual ([Huntington-Klein 2026](#)).

Razón 1 Coincidencia: correlaciones espurias


A veces dos series se mueven juntas por **puro azar** o porque ambas crecen en el tiempo, sin ninguna relación real entre ellas. Una correlación **alta** (r) no garantiza ningún vínculo causal ([ver](#)):



Avistamientos de OVNI en Rhode Island vs. ascensos exitosos al Everest, 1975–2011 ($r = 0,92$). Fuente: tylervigen.com/spurious-correlations

Razón 2 Causa común: el confusor

🍦 **Ejemplo clásico:** las ciudades con más **ventas de helado** registran más **ahogamientos**. El helado no causa ahogamientos: el **calor** —una *causa común* que no está en el modelo— empuja a ambas variables a la vez.




Tip

La correlación helado–ahogamientos existe, pero se desvanece si comparamos días con la **misma temperatura**. El confusor “abre” un camino entre X e Y que **no** es causal.

Razón 3 — Causalidad inversa / simultaneidad

🚓 ¿Más **dotación policial** *causa* más **delito**? Los datos suelen mostrar esa correlación positiva, pero el sentido de la flecha está en buena parte **invertido**: las comunas con más delito son, precisamente, las que **reciben más policías**. Y como la política busca que la dotación *reduzca* el delito, **causa y efecto se determinan mutuamente** (*simultaneidad*).



Tip

Cuando Y también causa a X , el coeficiente de una regresión simple **mezcla los dos sentidos** y **no** puede leerse como el efecto de X sobre Y .



Pregunta N° 3

Un estudio encuentra una correlación positiva entre el número de **bomberos** enviados a un incendio y el **daño** causado por el fuego. ¿Cuál es la explicación más probable?

Seleccione la opción correcta

Los bomberos causan el daño

Los incendios más grandes requieren más bomberos y causan más daño

La correlación es exactamente cero

Deberíamos usar un R^2 más alto para resolver el problema

Revisar

Reiniciar

¿Qué falta? Sesgo de variable omitida

En nuestro modelo `wage ~ educ`, el coeficiente $\hat{\beta}_1$ **probablemente está sesgado** porque hay variables omitidas (experiencia, habilidad, sector, etc.) correlacionadas con la educación.

La solución: agregar **variables de control** al modelo → pasar de regresión **simple** a regresión **múltiple**.

```
1 # Clase 6: simple
2 lm(wage ~ educ, data = wage1)
3
4 # Clase 7: múltiple
5 lm(wage ~ educ + exper + tenure + female, data = wage1)
```

Nota

En la **Clase 7** agregaremos **variables de control** para “cerrar” el camino de algunos confusores *observables*. Aun así, esto **no** transforma la regresión en un análisis causal: identificar efectos causales de forma creíble excede el alcance de este curso.

Recapitulación

¿Qué aprendimos hoy?

Concepto	Idea clave
Pregunta → Modelo	Definir la pregunta, especificar $y = \beta_0 + \beta_1 x + u$, estimar
OLS	Minimiza la suma de residuos al cuadrado
$\hat{\beta}_1$	Cambio promedio en Y por cada unidad de cambio en X (o en % si hay logaritmos)
R^2	Proporción de variabilidad de Y explicada por el modelo
Gauss-Markov	Si se cumplen los supuestos, OLS es MELI
Significancia	p-value < 0.05 o IC que no incluye 0 → rechazamos $H_0 : \beta_1 = 0$
Correlación ≠ Causalidad	Se requiere un contrafactual válido para estimar un efecto causal

Funciones clave de hoy

```
1 # Estimar la regresión
2 modelo <- lm(y ~ x, data = datos)
3
4 # Coeficientes como tibble
5 broom::tidy(modelo, conf.int = TRUE)
6
7 # Métricas del modelo (R², sigma, n, p-value global)
8 broom::glance(modelo)
9
10 # Visualizar la recta con ggplot
11 ggplot(datos, aes(x, y)) +
12   geom_point() +
13   geom_smooth(method = "lm")
```

Bibliografía

Heiss, Florian. 2020. *Using R for Introductory Econometrics*. Düsseldorf.

Huntington-Klein, Nick. 2026. *The effect: an introduction to research design and causality*. Second edition. A Chapman & Hall Book. Boca Raton London New York: CRC Press.

Wooldridge, Jeffrey M. 2020. *Introductory econometrics: a modern approach*. Seventh edition. Australia Brazil Mexico Singapore United Kingdom United States: Cengage.